

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки магистров по направлению

01.04.02 Прикладная математика и информатика

Трутнев Алексей Игоревич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Кластеризация в пространствах большой размерности

Рецензент

Научный руководитель
д-р физико-математических
наук, проф.

В.А. Калягин

Нижний Новгород, 2025

Содержание

1	Результаты исследования	3
1.1	Эксперимент с 2 кластерами	4
1.1.1	Влияние метрики Минковского на качество кластеризации при снижении размерности	4
1.1.2	Влияние методов снижения размерности на качество кластеризации фиксированном значении параметра расстояния Минковского	9

1 Результаты исследования

Алгоритм k-Means лучше всего работает с данными, которые удовлетворяют следующим условиям: сферические кластеры (данные должны группироваться вокруг k центров кластеров, имея примерно равное расстояние от центров до границ кластеров), равная плотность кластеров (если плотности кластеров сильно различаются, алгоритм может неправильно разделить данные), разделенные кластеры (расстояния между кластерами достаточно большие по сравнению с их собственными радиусами), гомогенные размеры кластеров (алгоритм лучше справляется, когда кластеры имеют похожий размер). В данной работе рассматриваются синтетические наборы, состоящие из смесей нормальных распределений с фиксированным Σ и μ . Плотность смеси нормальных распределений:

$$f(x) = \sum_{l=1}^k p_l f_l(x), \quad x = (x^1, x^2, \dots, x^d), p_l > 0, \sum_{l=1}^k p_l = 1.$$

Для каждого из синтетических наборов данных матрицы ковариаций фиксируются как единичные диагональные матрицы $\Sigma = I_d$. С помощью параметра t математические ожидания распределений могут быть сближены или разнесены по правилу:

$$\mu_i(t) = \mu_i + t \left(\frac{\sum_{j=1}^k \mu_j}{k} - \mu_i \right), \quad 0 \leq t \leq 1, \forall i \in [1, k]$$

В качестве методов предобработки были исследованы следующие методы:

- Locally Linear Embedding (LLE),
- Multidimensional Scaling (MDS),
- Principal Component Analysis (PCA),
- Spectral Embeddings (SE),
- Uniform Manifold Approximation and Projection (UMAP).

1.1 Эксперимент с 2 кластерами

Для синтетического набора, состоящего из смеси 2 нормальных распределений, заданы математические ожидания по правилу:


$$\mu_1 = (-4, 0, 0, \dots)$$

$$\mu_2 = (4, 0, 0, \dots).$$


Результаты качества кластеризации взяты как среднее значение кластеризации в 100 запусках.

1.1.1 Влияние метрики Минковского на качество кластеризации при снижении размерности


На графиках ниже представлены результаты экспериментов по оценке влияния параметра метрики Минковского p при различных методах предобработки данных: 1 для LLE, 2 для MDS, 3 для PCA, 4 для SE, 5 для UMAP.




(a)



(b)




(c)




(d)


Рис. 1: Влияние параметра расстояния Минковского p на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. LLE используется в качестве метода снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).




(a)



(b)




(c)




(d)


Рис. 2: Влияние параметра расстояния Минковского p на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. MDS используется в качестве метода снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).




(a)



(b)




(c)




(d)


Рис. 3: Влияние параметра расстояния Минковского p на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. PCA используется в качестве метода снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).




(a)



(b)



(c)



(d)

Рис. 4: Влияние параметра расстояния Минковского p на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. SE используется в качестве метода снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).




Рис. 5: Влияние параметра расстояния Минковского p на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. UMAP используется в качестве метода снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

1.1.2 Влияние методов снижения размерности на качество кластеризации фиксированном значении параметра расстояния Минковского

На графиках ниже представлены результаты экспериментов по оценке поведения различных методов снижения размерности при фиксированном параметре метрики Минковского $p = 0.5$.




Рис. 6: Анализ влияния различных методов снижения размерности данных при фиксированном расстояния Минковского $p = 0.5$ на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.4$. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).