

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки магистров по направлению

01.04.02 Прикладная математика и информатика

Трутнев Алексей Игоревич

КУРСОВАЯ РАБОТА

Кластеризация в пространствах большой размерности

Научный руководитель
д-р физико-математических
наук, проф.

В.А. Калягин

Нижний Новгород, 2024

Содержание

1	Введение	4
2	Обзор литературы	6
2.1	Кластеризация без учителя	6
2.1.1	Кластеризация на основе центроидов	6
2.1.2	Кластеризация на основе плотности	7
2.1.3	Иерархическая кластеризация	7
2.2	Проблемы пространства большой размерности	8
2.3	Подходы к улучшению работы с данными в пространствах большой размерности	9
2.3.1	Методы снижения размерности	9
2.3.2	Использование расстояния Минковского	10
2.3.3	Кластеризация с частичным привлечением учителя	11
3	Постановка проблемы	13
3.1	Основные обозначения	13
3.2	Формулирование задачи кластеризации без учителя	13
3.3	Формулирование задачи обучения с учителем	14
3.3.1	Выбор метода кластеризации	14
3.3.2	Выбор метрики качества	15
4	Предложенный метод	18
4.1	«Мягкое» привлечение учителя	18
4.2	«Жесткое» привлечение учителя	18
4.3	Алгоритм k-Means с метрикой Минковского и частичным привлечением учителя	19
5	Результаты исследования	21
5.1	Эксперимент с 2 кластерами	22

5.2 Эксперимент с 3 кластерами	26
6 Заключение	31
Список литературы	32

1 Введение

Кластеризация является важным инструментом анализа данных, который находит широкое применение во многих областях, включая биоинформатику, медицину, финансы, исследования социальных сетей и многие другие. Однако с увеличением размерности данных стандартные методы кластеризации могут столкнуться с проблемой низкого качества разбиения.

Проблема качества кластеризации особенно остра в многомерном пространстве, где количество признаков значительно превышает количество объектов. Это явление, известное как «проклятие размерности», приводит к тому, что традиционные методы кластеризации становятся менее эффективными из-за разреженности данных и трудностей в интерпретации результатов.

Одним из способов преодоления этой проблемы является привлечение учителя для предоставления дополнительной информации о данных. Однако разметка больших наборов данных для обучения моделей машинного обучения с учителем требует значительных временных и финансовых затрат. В связи с этим возникает потребность в разработке методов кластеризации, которые могли бы использовать только часть размеченных данных для улучшения качества разбиения.

В данной работе исследуется подход кластеризации с частичным привлечением учителя (semi-supervised clustering), который позволяет использовать ограниченное количество размеченных данных для повышения эффективности кластеризации в пространствах большой размерности.

Для достижения данной цели поставлены следующие задачи:

1. систематизировать и проанализировать существующие методы кластеризации,
2. реализовать алгоритм кластеризации с частичным привлечением учителя в пространствах большой размерности,

3. провести экспериментальное исследование и анализ влияния параметров алгоритма на качество кластеризации.

В результате выполнения поставленных задач будет разработан новый метод кластеризации с частичным привлечением учителя. Особенностью предложенного метода является его способность эффективно работать с ограниченным объемом размеченных данных, что делает его особенно привлекательным для сфер, где разметка данных является сложной, трудоемкой и дорогостоящей задачей, включая анализ текста, аудиосигналов изображений и других. Кроме того, данная работа предоставит возможность глубже исследовать и понять, как ограниченный объем размеченных данных может быть использован для улучшения качества кластеризации. Это позволит существенно оптимизировать процесс разметки данных и снизить затраты на него.

2 Обзор литературы

Кластеризация – один из ключевых методов машинного обучения, использующийся в анализе данных [19], компьютерном зрении [9], [21], направленный на разделение множества объектов на группы (кластеры) таким образом, чтобы все объекты внутри одного кластера были похожи друг на друга и не похожи на объекты из других кластеров.

2.1 Кластеризация без учителя

Кластеризация – задача обнаружения скрытых закономерностей в данных без привлечения учителя, которая минимизирует внутрикластерные расстояния и максимизирует межкластерное расстояние. Существует несколько подходов к решению классической задачи кластеризации. В такой задаче на вход алгоритму подаются только объекты, без информации об их классах.

2.1.1 Кластеризация на основе центроидов

Одним из таких подходов является кластеризация на основе центроидов (centroid-based clustering). Это метод, при котором каждый кластер описывается центроидом – «центром» этого кластера. Присваивание к кластерам производится с опорой на расстояние между объектами и центроидами. Наиболее известным алгоритмом этого типа является k-Means [16]. Алгоритм k-Means – простой и эффективный алгоритм оптимизации межкластерного расстояния. К минусам данного подхода можно отнести сильную зависимость от начальных условий, а также необходимость задачи начального числа кластеров. Еще одним алгоритмом, опирающимся на идею центроидов, является k-medoids [15]. Предложенный подход меняет способ подсчета расстояний с евклидово на расстояние манхеттенское, и, как следствие, использует в качестве центроидов медианы кластеров. Одним из способов решить проблему начальных центроидов

алгоритмов k-Means и k-medoids является подход k-Means++ [4], использующий вероятностный подход для генерации начальных точек.

2.1.2 Кластеризация на основе плотности

Еще одним из методов решения задачи кластеризации является кластеризация на основе плотности (density-based clustering). Она основывается на поиске областей с высокой плотностью данных, разделенных областями с низкой плотностью данных. Одним из самых алгоритмов этого типа является DBSCAN [10]. Очень важным преимуществом подходов на основе плотности является поиск кластеров произвольной формы и устойчивость к шумным данным. Еще одним часто используемым методом является OPTICS [2].

2.1.3 Иерархическая кластеризация

Иерархическая кластеризация строит дерево кластеров (дендрограмму), каждый уровень которого отражает определенный этап объединения или разделения кластеров. Агломеративная кластеризация [18] начинает процесс с этапа, когда каждый объект образует свой кластер и постепенно объединяет их в один кластер для всех объектов. Дивизионная иерархическая кластеризация [14] начинается с одного кластера для всех объектов и постепенно увеличивает количество кластеров. Построение дендрограммы является преимуществом иерархической кластеризации, которая позволяет по количеству кластеров определить разбиение объектов без необходимости перезапускать алгоритм. Поэтому выбор метода определения расстояния между кластерами имеет очень сильное влияние на качество работы алгоритма.

Single Linkage (Метод ближнего соседа) Метод Single Linkage, или метод ближнего соседа [20], определяет минимальное расстояние между двумя любыми объектами из разных кластеров. Данный подход позволяет определять

кластеры произвольной формы и хорошо работает с вытянутыми кластерами. Однако чувствителен к шуму и форме кластеров.

Complete Linkage (Метод дальнего соседа) Метод Complete Linkage, или метод дальнего соседа [8], определяет максимальное расстояние между двумя любыми объектами из разных кластеров. В отличие от Single Linkage, данный подход позволяет создавать более компактные кластеры, однако все также сильно чувствителен к выбросам и шуму.

Average Linkage (Метод средней связи) Метод Average Linkage, или метод средней связи, [25] определяет расстояние между кластерами как среднее расстояние между всеми парами объектов из этих кластеров. Как следствие, значительно лучше справляется с шумными данными, создает более устойчивые и компактные кластеры. Однако среднее расстояние не всегда достаточно хорошо описывает структуру анализируемых данных.

2.2 Проблемы пространства большой размерности

Кластеризация в пространствах большой размерности представляет значительную проблему для алгоритмов анализа данных. В случае, когда присутствует большое количество признаков в данных, эффективность и качество алгоритмов может снижаться. Данный эффект называется «проклятие размерности» [6].

Вычислительная сложность Одной из главных проблем при работе с пространствами большой размерности является увеличивающаяся вычислительная сложность алгоритмов. Например, для алгоритма k-Means каждая итерация оптимизации центроида требует вычисление расстояний между каждым объектом и каждым центроидом по каждой из координат. При росте измерений, значительно возрастает вычислительная сложность.

Разреженность данных По мере роста числа признаков (размерности), объекты становятся более разреженными, а расстояние между ними более равномерными [6], что значительно снижает эффективность расстояния Евклида [7] при определении расстояний между кластерами и между объектами и центроидами, а также снижают разделительную способность кластеризации на основе плотности. Кластеры становятся менее различимы, а количество шума возрастает.

2.3 Подходы к улучшению работы с данными в пространствах большой размерности

Для преодоления проблем, связанных с кластеризацией данных большой размерности, используются различные подходы.

2.3.1 Методы снижения размерности

Метод главных компонент (Principal Component Analysis) Метод главных компонент (PCA) [13] – линейный метод перевода данных из одной размерности в меньшую, сохраняя как можно больше информации в данных. Преимущества данного алгоритма являются его простота и вычислительная эффективность, однако линейность метода ограничивает класс рассматриваемых задач и может потерять значительную часть информации при сильном уменьшении размерности.

t-Distributed Stochastic Neighbour Embedding (t-SNE) t-SNE [22] – это нелинейный вероятностный метод, который хорошо подходит для визуализации данных большой размерности, обнаружения кластеров и локальных структур. Метод использует расстояние Кульбака-Лейблера

$$D_{KL} = \sum_{i \neq l} P_{ij} \log\left(\frac{P_{ij}}{Q_{ij}}\right), \quad (1)$$

где P – совместная вероятность в пространстве большой размерности, а Q – совместная вероятность в пространстве с меньшей размерностью. Минимизируя функцию стоимости 1, стремится уменьшить размерность данных, сохраняя при этом структуру точек данных таким образом, чтобы попарные сходства сохранялись и схожие объекты находились близко друг к другу в пространстве меньшей размерности. Как следствие, t-SNE превосходно сохраняет нелинейную структуру данных, однако требует значительных вычислительных ресурсов.

2.3.2 Использование расстояния Минковского

Повышение качества кластеризации данных большой размерности можно достичь с помощью использования более чувствительной метрики расстояния, например, Минковского:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}. \quad (2)$$

Согласно исследованиям проблемы «проклятия размерности», связанных с применением различных метрик расстояния [1], были получены результаты, что расстояние Минковского может быть адаптирована для алгоритма k-Means и при различных значениях параметра p качество кластеризации может значительно возрасти. Одним из способов усовершенствования данного подхода – взвешивание признаков (feature weighting) в метрике Минковского:

$$d(x, y) = \left(\sum_{i=1}^n w_i |x_i - y_i|^p \right)^{\frac{1}{p}}, \quad (3)$$

где w_i - вес i признака. Вес признака может быть получен из разброса данных, в качестве применения алгоритма PCA или методов машинного обучения. Применение взвешенной метрики Минковского предоставляет мощный инструмент для решения проблемы низкого качества кластеризации в пространстве большой размерности благодаря учету важности признаков.

2.3.3 Кластеризация с частичным привлечением учителя

Одним из способов решить проблему снижения качества кластеризации данных большой размерности является помощь алгоритму кластеризации небольшим числом данных с заранее определенными кластерами (таргетами). Кластеризация с частичным привлечением учителя (Semi-supervised clustering) – это подход, использующий комбинацию размеченных (данные с известными кластерами) и неразмеченных (данные, кластера которых неизвестны) данных для улучшения результатов кластеризации. Этот подход позволяет добавить контроль в процесс кластеризации, что приводит к созданию различных кластеров с более четкой структурой, а также добавляет возможность использовать стандартные методы оценки качества результатов алгоритма, такие как точность (Accuracy), прецизионность (Precision) полнота (Recall). Среди алгоритмов кластеризации с частичным привлечением учителя можно выделить основные подходы использования ограниченного знания о классах исходных данных.

Привлечение учителя для генерации начальных кластеров Подход кластеризации с частичным привлечением учителя для генерации начального разбиения на кластеры (seeding) [5], [3] – это метод, в котором небольшой набор маркированных точек данных используют для формирования начальных кластеров, таким образом предоставляя алгоритму хорошую стартовую точку для оптимизационной задачи. В дальнейшем алгоритм кластеризации уже без учителя распространит начальные метки на оставшиеся немаркированные данные на основе мер схожести, обеспечивая сильное влияние начального приближения на весь процесс обучения.

Привлечение учителя для определения принадлежности к кластеру Одним из способов внести знания о кластерах в процесс обучения также является привлечение учителя для определения принадлежности к кластеру. Метод Semi-supervised clustering under a «compact-cluster» assumption [12], который основан

на допущении идеи компактности кластеров и минимизирует внутрикластерные расстояния, одновременно максимизируя межкластерные расстояния, обеспечивает четкость и компактность кластеров.

3 Постановка проблемы

3.1 Основные обозначения

В дальнейшем будут использоваться следующие основные обозначения. Пусть $X = \begin{pmatrix} x_i^j \end{pmatrix} \in \mathbb{R}^{n \times d}$ обозначает матрицу наблюдений размером $n \times d$, где каждый d -мерный объект $x_i = (x_i^1, x_i^2, \dots, x_i^d) \in \mathbb{R}^{1 \times d}$ представляет собой строковый вектор признаков для каждого наблюдения $i = 1, 2, \dots, n$. Вектор $x_j = (x_1^j, x_2^j, \dots, x_n^j)^\top \in \mathbb{R}^{n \times 1}$ означает столбец значений признака j для всех наблюдений $j = 1, 2, \dots, d$. Вектор $y = (y_1, y_2, \dots, y_n)^\top \in \mathbb{R}^{n \times 1}$ содержит значения целевой функции, представляющей искомые кластеры. Число кластеров обозначено как k , а разбиение наблюдений на кластеры — как $S = S_1, S_2, \dots, S_k$, где каждый кластер $S_l \subset 1, 2, \dots, n$ для $l = 1, 2, \dots, k$. Набор из k центров кластеров представлен через $c = c_1, c_2, \dots, c_k$, где каждый центр $c_l = (c_l^1, c_l^2, \dots, c_l^d) \in \mathbb{R}^{1 \times d}$ для $l = 1, 2, \dots, k$. Также используется диагональная матрица размерности d , обозначенная как I_d .

3.2 Формулирование задачи кластеризации без учителя

Задача кластеризации относится к типу задач «без учителя» (Unsupervised learning). Задача кластеризации – есть группировка объектов в наборы (группы), основываясь только на их сходстве между собой так, чтобы объекты внутри одной группы были больше похожи на представителей этой группы, чем другой.

Формальная запись задач имеет следующий вид: Для каждого d -мерного объекта x_i из множества объектов $X = x_1, x_2, \dots, x_n$, необходимо поставить в соответствие один из k кластеров $c = \{c_1, c_2, \dots, c_k\}$.

Для оценивания «схожести» объектов могут быть использованы разные метрики расстояния такие как Евклидово расстояние [16], Манхеттенское расстояние, [15], расстояние Минковского [1] и другие. А также различные способы оценки межкластерных расстояний, такие как Average Linkage [25], Complete

Linkage [8], Single Linkage [20].

Задача кластеризации на основе центроидов для расстояния Минковского с параметром p есть задача сложной невыпуклой оптимизации функционала качества (4), которая может быть решена с помощью эвристического алгоритма k-Means для метрики Минковского, где необходимо оптимизировать сумму расстояний между объектами внутри кластеров.

$$\begin{aligned} W_p(S; c) &= \sum_{l=1}^k \sum_{x \in S_l} \sum_{j=1}^d |x^j - c_l^j|^p \rightarrow \min, \\ x &= (x^1, x^2, \dots, x^d) \in R^{1 \times d}, \\ c_l &= (c_l^1, c_l^2, \dots, c_l^d) \in R^{1 \times d} \end{aligned} \tag{4}$$

3.3 Формулирование задачи обучения с учителем

В отличие от задачи кластеризации без учителя, в задаче кластеризации с учителем имеется доступ к части размеченных данных.

Формальная запись задач имеет следующий вид: Дано множество d -мерных объектов $X = \{x_1, x_2, \dots, x_n\}$ и множество меток $\{t_1, t_2, t_3, \dots, t_r\} = T \subset X$ для r объектов, что $r \leq n$. Целью является разделение этого множества на k кластеров $c = \{c_1, c_2, \dots, c_k\}$ таким образом, чтобы объекты внутри каждого кластера принадлежали к одному и тому же классу, при условии, что эти классы известны. Функционал качества кластеризации в этом случае может включать в себя как внутрикластерные, так и межкластерные расстояния, а также дополнительные условия на основе разметки классов.

3.3.1 Выбор метода кластеризации

В данной работе основой для алгоритма кластеризации с учителем служит реализация k-Means с метрикой Минковского для пространств большой размерности, поскольку k-Means – легко интерпретируемый подход, основанный на оптимизации суммарного квадратичного отклонения внутри кластеров. Выбор

k-Means также обусловлен его основными преимуществами: простотой реализации (существует большое число реализаций и оптимизаций данного подхода), высокой скоростью работы (на небольших наборах данных алгоритм способен сходиться за очень короткое время). Алгоритм k-Means выполняет кластеризацию данных, оптимизируя суммарное квадратичное отклонение внутри кластеров. Его работа состоит из нескольких этапов:

1. Инициализация. Фиксируется параметр k – число кластеров, которые необходимо найти, после чего центроиды кластеров выбираются случайным образом.
2. Присвоение данных кластерам. Каждый объект данных присваивается кластеру, чей центроид на основе выбранной метрики расстояния окажется ближе всего.
3. Обновление центроидов. Центроиды пересчитываются на основе объектов из соответствующих кластеров.
4. Итеративное повторение шагов 1, 2 и 3.

3.3.2 Выбор метрики качества

Для оценки качества предложенного алгоритма кластеризации были выбраны метрики *Accuracy*, *NMI*, *ARI*, *AMI*.

Rand Index (*RI*) является метрикой, используемой для измерения сходства между двумя различными кластеризациями или разбиениями одного и того же набора данных. Основная идея *RI* заключается в том, чтобы подсчитать долю пар объектов, которые находятся в одном и том же кластере в обоих разбиениях (кластеризациях). Для того чтобы определить *RI*, вводятся следующие обозначения. Пусть X – набор, состоящий из n объектов для кластеризации, в котором a пар объектов попали в один кластер, а b пар попали в разные кластеры. Тогда

метрика Rand Index (RI) будет иметь вид:

$$RI = \frac{a + b}{C_2^n}. \quad (5)$$

Adjusted Rand Index (ARI) – скорректированная версия Rand Index, предназначенная для измерения сходства между двумя кластеризациями, путем корректировки метрики RI . ARI может принимать значения в промежутке $[0; 1]$, где значение 1 соответствует идентичным кластеризациям, а значение 0 означает, что кластеризации случайны.

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}, \quad (6)$$

где $E[RI]$ – оценка математического ожидания RI , а $\max(RI)$ – максимальное значение Rand Index, полученное в результате кластеризаций.

Mutual Information (MI) измеряет степени зависимости между двумя различными разбиениями одного и того же набора данных на кластеры. Обозначим за U и V два разбиения набора данных X , состоящего из n объектов, что $|U_i|$ – есть количество объектов в кластере U_i , а $|V_j|$ в кластере V_j . Обозначим энтропию за $H(U)$.

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{n} \log \frac{n|U_i \cap V_j|}{|U_i||V_j|}, \quad (7)$$

Normalized Mutual Information (NMI) – вариант MI , который нормализуется для того, чтобы значения можно было интерпретировать на отрезке от 0 до 1. Метрика используется для измерения сходства между двумя различными разбиениями одного и того же набора данных на кластеры.

$$NMI(U, V) = \frac{MI(U, V)}{\text{mean}(H(U), H(V))}. \quad (8)$$

Adjusted Mutual Information (AMI) нормализуется относительно максимальной величины, которую может принять взаимная информация, что позволяет

оценивать сходство между разбиениями на независимых от размера кластеров данных. Она принимает значения в интервале от 0 до 1, где значение 1 означает идентичные разбиения, а значение 0 указывает на полное отсутствие сходства. Данная метрика широко используется в оценке качества различных методов кластеризации или сегментации данных, особенно когда требуется оценить сходство результатов, полученных из разных экспериментов или алгоритмов кластеризации.

$$AMI(U, V) = \frac{MI(U, V) - E[MI(U, V)]}{mean(H(U), H(V)) - E[MI(U, V)]}. \quad (9)$$

Accuracy используется для оценки качества классификации, рассматривая степень совпадения найденных и референтных значений. Для оценки качества кластеризации без учителя использование Accuracy может не давать корректных результатов, так как она опирается только на номера меток, которые в кластеризации могут различаться из-за различной нумерации кластеров. Однако при использовании подхода кластеризации с частичным привлечением учителя, где порядок нумерации кластеров совпадает с референтными значениями, данная метрика отражает насколько точно разделяются объекты на кластеры (классы).

4 Предложенный метод

Одним из способов повышения точности алгоритма кластеризации на основе центроидов для метрики Минковского является частичное привлечение учителя. В данной работе предлагается два способа введения информации о метках в алгоритм кластеризации.

4.1 «Мягкое» привлечение учителя

Мягкое привлечение учителя в задачу кластеризации (Soft semi-supervised clustering) – подход, предлагающий использовать информацию о метках в обучаемом наборе данных для генерации начальных центров вместо выбора их случайным методом. Для расчета начальных центроидов используется алгоритм (1), где каждый центроид высчитывается на основе размеченных объектов. Данный подход позволяет задать начальное приближение задачи оптимизации (4), которая в дальнейшем решается алгоритмом k-Means для метрики Минковского.

Algorithm 1 Выбор начальных центроидов с частичным привлечением учителя

k : Количество классов

X : Множество объектов

Y : Множество меток

Выбрать случайным образом k центров кластеров из X

for кластер $i \in \{1, 2, \dots, k\}$ **do**

 выбрать все точки x из X , у которых есть метки в Y равные k

 вычислить центроид c_i на основе выбранных точек

end for

4.2 «Жесткое» привлечение учителя

Жесткое привлечение учителя в задачу кластеризации (Hard semi-supervised clustering) – подход, предлагающий расширить использование информации о

метках в обучаемом наборе данных. В данном подходе предлагается использовать начальное приближение из алгоритма (1), а также «фиксировать» объекты с известными метками в их кластерах, фактически запрещая переходы объектов из одного кластера в другой, что влияет как на точность, так и на скорость схождения алгоритма.

Algorithm 2 Выбор оптимального кластера для объекта

x : объект

$T = \{t_1, t_2, \dots, t_r\}$: Множество меток для r объектов

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

if T содержит метку t для объекта x **then**

 присвоить объект x кластеру C_t

else

 вычислить d_l - расстояние до каждого центра $c_l \in c$

 присвоить объект x к ближайшему кластеру из C

end if

4.3 Алгоритм k-Means с метрикой Минковского и частичным привлечением учителя

Таким образом, алгоритм кластеризации с метрикой Минковского и частичным привлечением учителя имеет следующий вид.

Algorithm 3 k-Means с метрикой Минковского и частичным привлечением учителя

k : Количество классов

X : Множество объектов

$T = \{t_1, t_2, \dots, t_r\}$: Множество меток для r объектов

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

Выбрать начальное разбиение с помощью алгоритма (1)

while центры не стабилизировались **do**

for точка $x \in X$ **do**

 присвоить x оптимальному кластеру согласно алгоритму (2)

end for

for кластер $C_i \in C$ и центр $c_i \in c$ **do**

 пересчитать центр c_i кластера как среднее значение из точек внутри кластера C_i

end for

end while

Алгоритм был реализован при использовании языка программирования Python 3.10 и библиотеки *pandas* (1.5.2), *scikit-learn* (1.2.0), *scipy* (1.10.0), *numpy* (1.24.3). Для анализа качества алгоритма была разработана система автоматического анализа кода и тестирования алгоритма на платформе GitHub Actions. Качество кода проверялось с использованием библиотек *pylint* (2.15.9) и *isort* (5.11.4). Для тестирования алгоритма были разработаны 168 Unit тестов с использованием библиотеки *pytest* (7.2.0).

5 Результаты исследования

Алгоритм k-Means лучше всего работает с данными, которые удовлетворяют следующим условиям: сферические кластеры (данные должны группироваться вокруг k центров кластеров, имея примерно равное расстояние от центров до границ кластеров), равная плотность кластеров (если плотности кластеров сильно различаются, алгоритм может неправильно разделить данные), разделенные кластеры (расстояния между кластерами достаточно большие по сравнению с их собственными радиусами), гомогенные размеры кластеров (алгоритм лучше справляется, когда кластеры имеют похожий размер). В данной работе рассматриваются синтетические наборы, состоящие из смесей нормальных распределений с фиксированным Σ и μ . Плотность смеси нормальных распределений:

$$f(x) = \sum_{l=1}^k p_l f_l(x), \quad x = (x^1, x^2, \dots, x^d), p_l > 0, \sum_{l=1}^k p_l = 1.$$

Для каждого из синтетических наборов данных матрицы ковариаций фиксируются как единичные диагональные матрицы $\Sigma = I_d$. С помощью параметра t математические ожидания распределений могут быть сближены или разнесены по правилу:

$$\mu_i(t) = \mu_i + t \left(\frac{\sum_{j=1}^k \mu_j}{k} - \mu_i \right), \quad 0 \leq t \leq 1, \forall i \in [1, k]$$

.

Пусть $\alpha = \frac{|Y|}{|X|}$ – коэффициент размеченных данных в диапазоне от 0 (в данных нет меток) до 1 (все данные размечены). В данной работе исследуются параметры $\alpha \in [0, 0.2]$ для анализа качества кластеризации с частичным использованием учителя.

5.1 Эксперимент с 2 кластерами

Для синтетического набора, состоящего из смеси 2 нормальных распределений, заданы математические ожидания по правилу:

$$\mu_1 = (-4, 0, 0, \dots)$$

$$\mu_2 = (4, 0, 0, \dots).$$

Метрика Минковского с параметром $p = 2$ Результаты работы алгоритма кластеризации для метрики Минковского с параметром $p = 2$ на данных, состоящих из 2 кластеров с коэффициентом сближения $t = 0.8$, представлены на рисунке 1. Алгоритм HardSSLKMeans с фиксацией объектов с известными метками в их кластерах показывает значительно лучшую скорость схождения, а также более высокие результаты по всем рассматриваемым метрикам: *Accuracy*, *ARI*, *AMI*, *NMI*. Очевидно, что при добавлении учителя качество кластеризации должно улучшаться. В таблице 1 представлено сравнение числовых значений рассматриваемых метрик. HardSSLKMeans показал *Accuracy* 0.77, что на 67.39% лучше алгоритма кластеризации без использования учителя.




Рис. 1: Влияние α на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 2$. Результаты для (a) Accuracy; (b) ARI; (c) AMI; (d) NMI, а также на время работы алгоритма (e).

Таблица 1: Результаты эксперимента кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 2$

Алгоритм	α	Accuracy	ARI	AMI	NMI	Время
LKMeans	0	0.46	0.00	0.00	0.00	0.02
HardSSLKMeans	0.1	0.68	0.12	0.09	0.10	0.02
	0.15	0.77	0.28	0.22	0.22	0.02
	0.2	0.74	0.26	0.22	0.25	0.02
SoftSSLKMeans	0.1	0.53	0.00	0.00	0.00	0.02
	0.15	0.69	0.14	0.10	0.11	0.02
	0.2	0.69	0.14	0.10	0.11	0.02

Метрика Минковского $0 < p < 1$ Результаты работа алгоритма кластеризации для метрики Минковского с параметром $p = 0.5$ на данных, состоящих из 2 кластеров с коэффициентом сближения $t = 0.8$, представлены на рисунке 2. Алгоритм HardSSLKMeans с фиксацией объектов с известными метками в их кластерах показывает лучшие результаты. При $\alpha = 0.15$ оба алгоритма HardSSLKMeans и SoftSSLKMeans показывают сравнимые результаты. При $\alpha = 0.2$ HardSSLKMeans опережает k-Means и SoftSSLKMeans на 48.89% и 4.68% соответственно.




Рис. 2: Влияние α на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 0.5$. Результаты для (a) Accuracy; (b) ARI; (c) AMI; (d) NMI, а также на время работы алгоритма (e).

Таблица 2: Результаты эксперимента кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 0.5$

Алгоритм	α	Accuracy	ARI	AMI	NMI	Время
LKMeans	0	0.45	0.00	0.00	0.01	0.19
HardSSLKMeans	0.1	0.63	0.06	0.04	0.05	0.19
	0.15	0.66	0.09	0.07	0.08	0.18
	0.2	0.67	0.08	0.07	0.08	0.18
SoftSSLKMeans	0.1	0.61	0.04	0.03	0.04	0.21
	0.15	0.66	0.09	0.07	0.08	0.21
	0.2	0.64	0.08	0.07	0.07	0.22

5.2 Эксперимент с 3 кластерами

Для синтетического набора, состоящего из смеси 3 нормальных распределений, заданы математические ожидания по правилу:

$$\mu_1 = (4, 0, 0, \dots)$$

$$\mu_2 = (0, 4, 0, \dots)$$

$$\mu_3 = (0, 0, 4, \dots).$$

Метрика Минковского с параметром $p = 2$ Для данных из 3 кластеров с коэффициентом сближения $t = 0.8$ результаты работа алгоритма кластеризации для метрики Минковского с параметром $p = 0.5$ представлены на рисунке 4 и в таблице 4. Лучший результат по метрикам точности достигается при использовании алгоритма *SoftSSLKMeans* с параметром $\alpha = 0.2$. В сравнении с алгоритмом k-Means метрика *Accuracy* улучшается на 84.38%, *ARI* и *NMI* улучшаются в 14 раз, *AMI* улучшается в 12 раз.




Рис. 3: Влияние α на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 3 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 0.5$. Результаты для (a) Accuracy; (b) ARI; (c) AMI; (d) NMI, а также на время работы алгоритма (e).

Таблица 3: Результаты эксперимента кластеризации 100 20-мерных объектов, сгенерированных вокруг 3 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 2$

Алгоритм	α	Accuracy	ARI	AMI	NMI	Время
LKMeans	0	0.32	0.01	0.01	0.01	0.04
HardSSLKMeans	0.1	0.34	0.00	0.01	0.02	0.04
	0.15	0.43	0.04	0.03	0.05	0.03
	0.2	0.33	0.00	0.00	0.02	0.03
SoftSSLKMeans	0.1	0.51	0.06	0.06	0.08	0.04
	0.15	0.53	0.07	0.09	0.011	0.03
	0.2	0.59	0.14	0.12	0.14	0.03

Метрика Минковского $0 < p < 1$ Для данных из 3 кластеров с коэффициентом сближения $t = 0.8$ результаты работы алгоритма кластеризации для метрики Минковского с параметром $p = 0.5$ представлены на рисунке 4 и в таблице 4. Лучший результат по метрикам точности достигается при использовании алгоритма *HardSSLKMeans* с параметром $\alpha = 0.2$. В сравнении с алгоритмом k-Means метрика *Accuracy* улучшается в 2.04 раза, *ARI* улучшается на 16.67%, *AMI* улучшается на 20%, *NMI* улучшается на 14.29%. Наибольшее сокращение времени работы алгоритма на 11.11% достигается при $\alpha = 0.1$.




Рис. 4: Влияние α на качество кластеризации 100 20-мерных объектов, сгенерированных вокруг 3 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 0.5$. Результаты для (a) Accuracy; (b) ARI; (c) AMI; (d) NMI, а также на время работы алгоритма (e).

Таблица 4: Результаты эксперимента кластеризации 100 20-мерных объектов, сгенерированных вокруг 2 центров с параметром сближения кластеров $t = 0.8$ и параметром метрики Минковского $p = 0.5$

Алгоритм	α	Accuracy	ARI	AMI	NMI	Время
LKMeans	0	0.25	0.06	0.05	0.07	0.20
HardSSLKMeans	0.1	0.33	0.02	0.02	0.04	0.18
	0.15	0.34	0.03	0.02	0.04	0.20
	0.2	0.51	0.07	0.06	0.08	0.20
SoftSSLKMeans	0.1	0.27	0.00	0.01	0.03	0.26
	0.15	0.41	0.01	0.01	0.03	0.23
	0.2	0.41	0.00	0.00	0.02	0.23

6 Заключение

В работе предлагаются и сравниваются два подхода введения учителя в процесс кластеризации k-Means для метрики Минковского для пространств большой размерности *SoftSSLKMeans* и *HardSSLKMeans*. *SoftSSLKMeans* использует идею введения учителя для генерации начального разбиения размеченных объектов на кластеры. *HardSSLKMeans* фиксирует метки размеченных объектов и не дает им сменить кластер в процессе решения задачи оптимизации. Оба алгоритма показывают значительно лучшие результаты в сравнении с алгоритмом k-Means без учителя. В частности, на 3 кластерах *SoftSSLKMeans* с 20% размеченными данными в среднем превосходит k-Means на 74.18%, *HardSSLKMeans* с 20% размеченными данными в среднем превосходит k-Means на 53.56%. На 2 кластерах *HardSSLKMeans* с 15% размеченными данными в среднем превосходит k-Means на 57%. Код проекта доступен по ссылке github.com/alexgiving/LKMeans.

Список литературы

- [1] C. C. Aggarwal, A. Hinneburg, and D. A. Keim, “On the surprising behavior of distance metrics in high dimensional spaces,” in *Proceedings of the 8th International Conference on Database Theory*, ser. ICDT '01. Berlin, Heidelberg: Springer-Verlag, 2001, p. 420–434.
- [2] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander, “Optics: Ordering points to identify the clustering structure,” *SIGMOD Rec.*, vol. 28, no. 2, p. 49–60, jun 1999. [Online]. Available: <https://doi.org/10.1145/304181.304187>
- [3] V. Antoine, N. Labroche, and V.-V. Vu, “Evidential seed-based semi-supervised clustering,” in *2014 Joint 7th International Conference on Soft Computing and Intelligent Systems (SCIS) and 15th International Symposium on Advanced Intelligent Systems (ISIS)*, 2014, pp. 706–711.
- [4] D. Arthur and S. Vassilvitskii, “k-means++: the advantages of careful seeding,” in *SODA '07: Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 2007, pp. 1027–1035.
- [5] S. Basu, A. Banerjee, and R. J. Mooney, “Semi-supervised clustering by seeding,” in *Proceedings of the Nineteenth International Conference on Machine Learning*, ser. ICML '02. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2002, p. 27–34.
- [6] R. Bellman, *Dynamic Programming*, 1st ed. Princeton, NJ, USA: Princeton University Press, 1957.
- [7] R. Cordeiro de Amorim and B. Mirkin, “Minkowski metric, feature weighting and anomalous cluster initializing in k-means clustering,” *Pattern Recognition*, vol. 45, no. 3, pp. 1061–1075, 2012. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320311003517>

- [8] D. Defays, “An efficient algorithm for a complete link method,” *The Computer Journal*, vol. 20, no. 4, pp. 364–366, 01 1977. [Online]. Available: <https://doi.org/10.1093/comjnl/20.4.364>
- [9] A. Demidovskij, A. Tugaryov, A. Trutnev, M. Kazyulina, I. Salnikov, and S. Pavlov, “Lightweight and elegant data reduction strategies for training acceleration of convolutional neural networks,” *Mathematics*, vol. 11, no. 14, 2023. [Online]. Available: <https://www.mdpi.com/2227-7390/11/14/3120>
- [10] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, ser. KDD’96. AAAI Press, 1996, p. 226–231.
- [11] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, “Array programming with NumPy,” *Nature*, vol. 585, no. 7825, pp. 357–362, Sept. 2020. [Online]. Available: <https://doi.org/10.1038/s41586-020-2649-2>
- [12] Z. Jiang, Y. Zhan, Q. Mao, and Y. Du, “Semi-supervised clustering under a “compact-cluster” assumption,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 5, pp. 5244–5256, 2023.
- [13] I. Jolliffe, *Principal Component Analysis*. Springer Verlag, 1986.
- [14] L. Kaufman and P. Rousseeuw, *Finding Groups in Data: An Introduction To Cluster Analysis*, 01 1990.
- [15] L. Kaufman and P. J. Rousseeuw, *Partitioning Around Medoids (Program*

- PAM). John Wiley & Sons, Inc., 2008, pp. 68–125. [Online]. Available: <http://dx.doi.org/10.1002/9780470316801.ch2>
- [16] S. Lloyd, “Least squares quantization in pcm,” *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [17] L. McInnes, J. Healy, N. Saul, and L. Großberger, “Umap: Uniform manifold approximation and projection,” *Journal of Open Source Software*, vol. 3, no. 29, p. 861, 2018. [Online]. Available: <https://doi.org/10.21105/joss.00861>
- [18] F. Murtagh and P. Legendre, “Ward’s hierarchical agglomerative clustering method: Which algorithms implement ward’s criterion?” *Journal of Classification*, vol. 31, no. 3, pp. 274–295, Oct 2014. [Online]. Available: <https://doi.org/10.1007/s00357-014-9161-z>
- [19] S. Setyaningsih, “Using cluster analysis study to examine the successful performance entrepreneur in indonesia,” *Procedia Economics and Finance*, vol. 4, pp. 286–298, 2012, international Conference on Small and Medium Enterprises Development with a Theme ?Innovation and Sustainability in SME Development? (ICSMED 2012). [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2212567112003437>
- [20] R. Sibson, “SLINK: An optimally efficient algorithm for the single-link cluster method,” *The Computer Journal*, vol. 16, no. 1, pp. 30–34, 01 1973. [Online]. Available: <https://doi.org/10.1093/comjnl/16.1.30>
- [21] B. Sorscher, R. Geirhos, S. Shekhar, S. Ganguli, and A. Morcos, “Beyond neural scaling laws: beating power law scaling via data pruning,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 19 523–19 536.

- [22] L. van der Maaten and G. Hinton, “Visualizing data using t-sne,” *Journal of Machine Learning Research*, vol. 9, no. 86, pp. 2579–2605, 2008. [Online]. Available: <http://jmlr.org/papers/v9/vandermaaten08a.html>
- [23] G. Van Rossum and F. L. Drake, *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace, 2009.
- [24] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, S. J. van der Walt, M. Brett, J. Wilson, K. J. Millman, N. Mayorov, A. R. J. Nelson, E. Jones, R. Kern, E. Larson, C. J. Carey, Í. Polat, Y. Feng, E. W. Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, E. A. Quintero, C. R. Harris, A. M. Archibald, A. H. Ribeiro, F. Pedregosa, P. van Mulbregt, and SciPy 1.0 Contributors, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [25] N. Xu, R. B. Finkelman, S. Dai, C. Xu, and M. Peng, “Average linkage hierarchical clustering algorithm for determining the relationships between elements in coal,” *ACS Omega*, vol. 6, no. 9, pp. 6206–6217, 2021, pMID: 33718711. [Online]. Available: <https://doi.org/10.1021/acsomega.0c05758>