

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки магистров по направлению

01.04.02 Прикладная математика и информатика

Трутнев Алексей Игоревич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Кластеризация в пространствах большой размерности

Рецензент

Научный руководитель
д-р физико-математических
наук, проф.

В.А. Калягин

Нижний Новгород, 2025

Содержание

1	Введение	4
2	Обзор литературы	7
2.1	Кластеризация без учителя	8
2.1.1	Кластеризация на основе центроидов	8
2.1.2	Кластеризация на основе плотности	9
2.1.3	Иерархическая кластеризация	9
2.1.4	Кластеризация на основе обучения Хебба	10
2.2	Проблемы пространства большой размерности	11
2.3	Подходы к улучшению работы с данными в пространствах большой размерности	11
2.3.1	Методы снижения размерности	12
2.3.2	Использование расстояния Минковского	16
2.3.3	Кластеризация с частичным привлечением учителя . . .	17
3	Постановка проблемы	19
3.1	Основные обозначения	19
3.2	Формулирование задачи кластеризации без учителя	19
3.3	Формулирование задачи обучения с учителем	20
3.3.1	Выбор метода кластеризации	20
3.3.2	Выбор метрики качества	21
4	Предложенный метод	24
4.1	«Мягкое» привлечение учителя	24
4.2	«Жесткое» привлечение учителя	24
4.3	Алгоритм k-Means с метрикой Минковского и частичным привлечением учителя	25
5	Заключение	27

1 Введение

Современный мир характеризуется стремительным ростом объемов данных, генерируемых в самых разных областях человеческой деятельности: от научных исследований и финансовых транзакций до пользовательской активности в цифровом пространстве. В условиях столь интенсивного накопления информации особое значение приобретает задача её систематизации и извлечения скрытых закономерностей. Одним из наиболее эффективных методов в этом направлении является кластеризация — процесс группировки объектов в такие кластеры, внутри которых элементы схожи между собой и существенно отличаются от элементов других групп.

Кластеризация относится к числу методов обучения без учителя в машинном обучении и применяется в случаях, когда отсутствуют заранее размеченные данные или ясные категории. В отличие от классификации, где алгоритму заранее известны метки классов, кластеризация стремится выявить структуру данных без предварительных предположений о числе или характере групп. Это делает метод особенно актуальным для задач, требующих начального анализа или сегментации больших массивов информации.

Методы кластеризации находят широкое применение в самых различных отраслях. Например, в биоинформатике алгоритмы кластеризации используются для анализа экспрессии генов и выявления групп с одинаковыми биологическими характеристиками. В маркетинге и аналитике потребительского поведения кластеризация позволяет сегментировать клиентов по предпочтениям, активности или географическому положению, способствуя более точной настройке рекламных кампаний. В области информационного поиска и анализа текстов кластеризация применяется для группировки документов по тематике, выявления спам-сообщений и упрощения навигации по большим корпусам текста. Не менее важна кластеризация и в изучении социальных сетей, где она помогает обнаруживать сообщества пользователей и анализировать паттерны взаимодей-

ствий.

С технической точки зрения кластеризация представляет собой математическую задачу, включающую выбор метрики расстояния, определение числа кластеров (в случае методов вроде k-средних), а также интерпретацию полученных групп. Существуют различные подходы к кластеризации: от иерархических моделей до методов, основанных на плотности (DBSCAN) и распределениях (ЕМ-алгоритм). Каждый из них обладает своими преимуществами и ограничениями, что делает актуальным вопрос выбора алгоритма в зависимости от конкретных характеристик данных.

Однако, несмотря на универсальность и популярность, методы кластеризации сталкиваются с рядом фундаментальных ограничений. Одним из наиболее значимых является ухудшение качества кластеризации при увеличении размерности данных. Эта проблема особенно актуальна в пространствах высокой размерности, когда число признаков существенно превышает количество объектов. Такое явление получило название «проклятие размерности» (curse of dimensionality).

Проклятие размерности выражается в том, что по мере увеличения числа признаков расстояния между объектами становятся всё менее информативными: большинство точек оказываются на одинаковом удалении друг от друга, и различия между ними нивелируются. Это приводит к разреженности данных, и традиционные метрики сходства (например, евклидово расстояние), используемые в методах вроде k-средних, теряют свою эффективность. Более того, высокая размерность усложняет интерпретацию результатов, увеличивает вероятность переобучения и делает вычислительные алгоритмы менее устойчивыми к шуму и выбросам.

Одним из эффективных подходов к решению этой проблемы является предварительное снижение размерности. Методы такие как PCA (Principal Component Analysis), MDS (Multi Dimensional Scaling) и UMAP (Uniform Manifold Approximation and Projection) позволяют сократить пространство признаков при сохранении

его ключевой структуры. Однако выбор метода снижения размерности и его влияние на итоговое качество кластеризации остаются открытыми вопросами и требуют детального анализа.

В данной работе рассматривается применение кластеризации с предварительным применением методов снижения размерности и анализ их влияния на качество кластеризации, устойчивости алгоритма и интерпретируемости результатов.

Для достижения данной цели поставлены следующие задачи:

1. систематизировать и проанализировать существующие методы кластеризации, а также методы снижения размерности,
2. реализовать алгоритм кластеризации предварительным применением методов снижения размерности,
3. провести экспериментальное исследование и анализ влияния методов снижения размерности на качество кластеризации,
4. разработать рекомендации по выбору методов снижения размерности в зависимости от характеристик данных и целей кластеризации.

Таким образом, работа направлена на разработку и экспериментальное обоснование стратегии, сочетающей в себе преимущества методов снижения размерности и алгоритма k -средних. Такой подход позволяет не только минимизировать негативные эффекты высокой размерности, но и повысить точность и надёжность кластеризации в условиях больших и сложных наборов данных.

2 Обзор литературы

Кластеризация — один из ключевых методов машинного обучения, используемый для обнаружения скрытых закономерностей в данных без привлечения учителя. Этот метод активно применяется в анализе данных [20], компьютерном зрении [9], биоинформатике [?], обработке естественного языка [?] и многих других областях науки и техники. Основная цель кластеризации заключается в разделении множества объектов на группы (кластеры) таким образом, чтобы все объекты внутри одного кластера были похожи друг на друга и значительно отличались от объектов других кластеров.

Кластеризация решает широкий спектр задач, включая:

- **Сегментация изображений:** разделение изображения на области схожих пикселей, что позволяет выделить объекты на изображении и улучшить качество последующего анализа.
- **Классификация текстов:** группировка текстовых документов по темам или стилям, что позволяет упростить поиск и анализ информации.
- **Кластеризация пользователей:** сегментация пользователей на группы схожих интересов и предпочтений, что позволяет персонализировать рекомендации и маркетинговые стратегии.
- **Обнаружение аномалий:** выявление аномальных точек, не принадлежащих ни одному кластеру или попадающих в редкие группы, что может свидетельствовать о мошенничестве, сбоях в оборудовании или ошибках в данных.
- **Разведочный анализ данных (EDA, Exploratory Data Analysis):** выявление скрытых закономерностей и структур в данных, что особенно полезно при работе с новыми или плохо изученными наборами данных.

Методы кластеризации можно классифицировать по нескольким критериям, включая метод формирования кластеров, алгоритмическую сложность, устойчивость к выбросам и способность обнаруживать кластеры сложной формы. Рассмотрим основные подходы к кластеризации.

2.1 Кластеризация без учителя

Кластеризация – задача обнаружения скрытых закономерностей в данных без привлечения учителя, которая минимизирует внутрикластерные расстояния и максимизирует межкластерное расстояние. Существует несколько подходов к решению классической задачи кластеризации. В такой задаче на вход алгоритму подаются только объекты, без информации об их классах.

2.1.1 Кластеризация на основе центроидов

Одним из таких подходов является кластеризация на основе центроидов (centroid-based clustering). Это метод, при котором каждый кластер описывается центроидом – «центром» этого кластера. Присваивание к кластерам производится с опорой на расстояние между объектами и центроидами. Наиболее известным алгоритмом этого типа является k-Means [17]. Алгоритм k-Means – простой и эффективный алгоритм оптимизации межкластерного расстояния. К минусам данного подхода можно отнести сильную зависимость от начальных условий, а также необходимость задачи начального числа кластеров. Еще одним алгоритмом, опирающимся на идею центроидов, является k-medoids [15]. Предложенный подход меняет способ подсчета расстояний с евклидово на расстояние манхеттенское, и, как следствие, использует в качестве центроидов медианы кластеров. Одним из способов решить проблему начальных центроидов алгоритмов k-Means и k-medoids является подход k-Means++ [4], использующий вероятностный подход для генерации начальных точек.

2.1.2 Кластеризация на основе плотности

Еще одним из методов решения задачи кластеризации является кластеризация на основе плотности (density-based clustering). Она основывается на поиске областей с высокой плотностью данных, разделенных областями с низкой плотностью данных. Одним из самых алгоритмов этого типа является DBSCAN [10]. Очень важным преимуществом подходов на основе плотности является поиск кластеров произвольной формы и устойчивость к шумным данным. Еще одним часто используемым методом является OPTICS [2].

2.1.3 Иерархическая кластеризация

Иерархическая кластеризация строит дерево кластеров (дендрограмму), каждый уровень которого отражает определенный этап объединения или разделения кластеров. Агломеративная кластеризация [19] начинает процесс с этапа, когда каждый объект образует свой кластер и постепенно объединяет их в один кластер для всех объектов. Дивизионная иерархическая кластеризация [14] начинается с одного кластера для всех объектов и постепенно увеличивает количество кластеров. Построение дендрограммы является преимуществом иерархической кластеризации, которая позволяет по количеству кластеров определить разбиение объектов без необходимости перезапускать алгоритм. Поэтому выбор метода определения расстояния между кластерами имеет очень сильное влияние на качество работы алгоритма.

Single Linkage (Метод ближнего соседа) Метод Single Linkage, или метод ближнего соседа [21], определяет минимальное расстояние между двумя любыми объектами из разных кластеров. Данный подход позволяет определять кластеры произвольной формы и хорошо работает с вытянутыми кластерами. Однако чувствителен к шуму и форме кластеров.

Complete Linkage (Метод дальнего соседа) Метод Complete Linkage, или метод дальнего соседа [8], определяет максимальное расстояние между двумя любыми объектами из разных кластеров. В отличие от Single Linkage, данный подход позволяет создавать более компактные кластеры, однако все также сильно чувствителен к выбросам и шуму.

Average Linkage (Метод средней связи) Метод Average Linkage, или метод средней связи, [26] определяет расстояние между кластерами как среднее расстояние между всеми парами объектов из этих кластеров. Как следствие, значительно лучше справляется с шумными данными, создает более устойчивые и компактные кластеры. Однако среднее расстояние не всегда достаточно хорошо описывает структуру анализируемых данных.

2.1.4 Кластеризация на основе обучения Хебба

Обучение Хебба (Hebbian Learning) [?] представляет собой биологически вдохновленный метод обучения, основанный на принципе: «нейроны, которые активируются вместе, соединяются». Этот метод можно применять для кластеризации данных путем адаптации весов нейронной сети или другого моделируемого механизма, усиливая связи между схожими объектами. Одним из подходов является использование сети нейронов, где веса обновляются по правилу Хебба: $\Delta w = \eta xy$, где x и y — входной и выходной сигналы, а η — коэффициент обучения. В результате объекты с высокой степенью корреляции усиливают свои связи, формируя естественные кластеры. Главным преимуществом обучения Хебба является его способность адаптироваться к данным и выделять скрытые закономерности без жестких предположений о числе кластеров. Однако метод чувствителен к выбору коэффициента обучения и требует тщательной настройки параметров.

2.2 Проблемы пространства большой размерности

Кластеризация в пространствах большой размерности представляет значительную проблему для алгоритмов анализа данных. В случае, когда присутствует большое количество признаков в данных, эффективность и качество алгоритмов может снижаться. Данный эффект называется «проклятие размерности» [6].

Вычислительная сложность Одной из главных проблем при работе с пространствами большой размерности является увеличивающаяся вычислительная сложность алгоритмов. Например, для алгоритма k-Means каждая итерация оптимизации центроида требует вычисление расстояний между каждым объектом и каждым центроидом по каждой из координат. При росте измерений, значительно возрастает вычислительная сложность.

Разреженность данных По мере роста числа признаков (размерности), объекты становятся более разреженными, а расстояние между ними более равномерными [6], что значительно снижает эффективность расстояния Евклида [7] при определении расстояний между кластерами и между объектами и центроидами, а также снижают разделительную способность кластеризации на основе плотности. Кластеры становятся менее различимы, а количество шума возрастает.

2.3 Подходы к улучшению работы с данными в пространствах большой размерности

Для преодоления проблем, связанных с кластеризацией данных большой размерности, используются различные подходы.

2.3.1 Методы снижения размерности

Метод главных компонент (Principal Component Analysis) Метод главных компонент (PCA) [13] – линейный метод перевода данных из одной размерности в меньшую, сохраняя как можно больше информации в данных. Преимущества данного алгоритма являются его простота и вычислительная эффективность, однако линейность метода ограничивает класс рассматриваемых задач и может потерять значительную часть информации при сильном уменьшении размерности.

Алгоритм метода главных компонент включает следующие шаги: стандартизация данных, вычисление ковариационной матрицы, вычисление собственных значений и собственных векторов, сортировка собственных значений и собственных векторов, выбор первых k собственных векторов для формирования матрицы проекции и преобразование исходных данных в новое подпространство. Алгоритм PCA представлен в алгоритме 1.

Algorithm 1 Метод главных компонент (PCA)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Стандартизация данных: $X_{\text{std}} = \frac{X - \mu}{\sigma}$, где μ – среднее значение, а σ – стандартное отклонение каждого признака.

Шаг 2: Вычисление ковариационной матрицы: $\Sigma = \frac{1}{n} X_{\text{std}}^T X_{\text{std}}$.

Шаг 3: Вычисление собственных значений и собственных векторов ковариационной матрицы: $\Sigma v_i = \lambda_i v_i$, где λ_i – собственные значения, а v_i – собственные векторы.

Шаг 4: Сортировка собственных значений и соответствующих им собственных векторов в порядке убывания $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$

Шаг 5: Выбор первых k собственных векторов для формирования матрицы проекции $W \in \mathbb{R}^{n \times k}$: $W = [v_1, v_2, \dots, v_k]$

Шаг 6: Преобразование исходных данных в новое подпространство: $Z = X_{\text{std}} W$

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k главными компонентами.

Метод многомерного шкалирования (Multidimensional Scaling) Метод многомерного шкалирования (MDS) [] – это метод снижения размерности, который

позволяет визуализировать данные в пространстве меньшей размерности, сохраняя при этом структуру исходных данных. MDS основан на идее сохранения попарных расстояний между объектами в пространстве меньшей размерности. Основным преимуществом MDS является его способность сохранять нелинейные структуры данных, однако метод требует значительных вычислительных ресурсов. Алгоритм MDS представлен в алгоритме 2.

Algorithm 2 Метод многомерного шкалирования (MDS)

Require: Матрица попарных расстояний $D \in \mathbb{R}^{m \times m}$ между m объектами

Шаг 1: Вычисление матрицы квадратов попарных расстояний: $B = -\frac{1}{2}D^2$

Шаг 2: Центрирование матрицы B : $B = B - \frac{1}{m}\mathbf{1}B - \frac{1}{m}B\mathbf{1} + \frac{1}{m^2}\mathbf{1}B\mathbf{1}$, где $\mathbf{1}$ – матрица, заполненная единицами.

Шаг 3: Вычисление собственных значений и собственных векторов матрицы B : $Bv_i = \lambda_i v_i$, где λ_i – собственные значения, а v_i – собственные векторы.

Шаг 4: Сортировка собственных значений и соответствующих им собственных векторов в порядке убывания $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$.

Шаг 5: Выбор первых k собственных векторов для формирования матрицы проекции $W \in \mathbb{R}^{m \times k}$: $W = [v_1, v_2, \dots, v_k]$.

Шаг 6: Преобразование исходных данных в новое подпространство: $Z = W\Lambda^{1/2}$, где Λ – диагональная матрица, содержащая k наибольших собственных значений.

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Uniform Manifold Approximation and Projection (UMAP) Метод Uniform

Manifold Approximation and Projection (UMAP) [] – это нелинейный метод снижения размерности, который позволяет визуализировать данные в пространстве меньшей размерности, сохраняя при этом структуру исходных данных. UMAP основан на идее сохранения локальной структуры данных, что позволяет сохранить нелинейные зависимости между объектами. Основным преимуществом UMAP является его способность сохранять нелинейные структуры данных, однако метод требует значительных вычислительных ресурсов. Алгоритм UMAP представлен в алгоритме 3.

Algorithm 3 Метод Uniform Manifold Approximation and Projection (UMAP)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы сходства S между объектами

Шаг 2: Вычисление матрицы расстояний D на основе S

Шаг 3: Выбор случайных точек в пространстве меньшей размерности

Шаг 4: Оптимизация позиций точек в пространстве меньшей размерности **return** Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Isometric Mapping (Isomap) Метод Isometric Mapping (Isomap) [] – это метод снижения размерности, который позволяет визуализировать данные в пространстве меньшей размерности, сохраняя при этом структуру исходных данных. Isomap основан на идее сохранения геодезических расстояний между объектами в пространстве меньшей размерности. Основным преимуществом Isomap является его способность сохранять нелинейные структуры данных, однако метод требует значительных вычислительных ресурсов. Алгоритм Isomap представлен в алгоритме 4.

Algorithm 4 Метод Isometric Mapping (Isomap)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы сходства S между объектами

Шаг 2: Вычисление матрицы расстояний D на основе S

Шаг 3: Вычисление матрицы геодезических расстояний G на основе D

Шаг 4: Выбор случайных точек в пространстве меньшей размерности

Шаг 5: Оптимизация позиций точек в пространстве меньшей размерности **return** Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Locally Linear Embedding (LLE) Метод Locally Linear Embedding (LLE) [] – это метод снижения размерности, который позволяет визуализировать данные в пространстве меньшей размерности, сохраняя при этом структуру исходных данных. LLE основан на идее сохранения локальной структуры данных, что позволяет сохранить нелинейные зависимости между объектами. Основным преимуществом LLE является его способность сохранять нелиней-

ные структуры данных, однако метод требует значительных вычислительных ресурсов. Алгоритм LLE представлен в алгоритме 5.

Algorithm 5 Метод Locally Linear Embedding (LLE)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы сходства S между объектами

Шаг 2: Вычисление матрицы весов W на основе S

Шаг 3: Вычисление матрицы весов W на основе S

Шаг 4: Выбор случайных точек в пространстве меньшей размерности

Шаг 5: Оптимизация позиций точек в пространстве меньшей размерности **return** Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Spectral Embedding (SSE) Метод Spectral Embedding (SSE) [] – это метод снижения размерности, который позволяет визуализировать данные в пространстве меньшей размерности, сохраняя при этом структуру исходных данных. SSE основан на идее сохранения локальной структуры данных, что позволяет сохранить нелинейные зависимости между объектами. Основным преимуществом SSE является его способность сохранять нелинейные структуры данных, однако метод требует значительных вычислительных ресурсов. Алгоритм SSE представлен в алгоритме 6.

Algorithm 6 Метод Spectral Embedding (SSE)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы сходства S между объектами

Шаг 2: Вычисление матрицы Лапласиана L на основе S

Шаг 3: Вычисление собственных значений и собственных векторов матрицы Лапласиана L

Шаг 4: Выбор первых k собственных векторов для формирования матрицы проекции $W \in \mathbb{R}^{m \times k}$

Шаг 5: Преобразование исходных данных в новое подпространство: $Z = W\Lambda^{1/2}$, где Λ – диагональная матрица, содержащая k наибольших собственных значений. **return** Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

t-Distributed Stochastic Neighbour Embedding (t-SNE) t-SNE [23] – это нелинейный вероятностный метод, который хорошо подходит для визуализации дан-

ных большой размерности, обнаружения кластеров и локальных структур. Метод использует расстояние Кульбака-Лейблера

$$D_{KL} = \sum_{i \neq l} P_{ij} \log\left(\frac{P_{ij}}{Q_{ij}}\right), \quad (1)$$

где P – совместная вероятность в пространстве большой размерности, а Q – совместная вероятность в пространстве с меньшей размерностью. Минимизируя функцию стоимости 1, стремится уменьшить размерность данных, сохраняя при этом структуру точек данных таким образом, чтобы попарные сходства сохранялись и схожие объекты находились близко друг к другу в пространстве меньшей размерности. Как следствие, t-SNE превосходно сохраняет нелинейную структуру данных, однако требует значительных вычислительных ресурсов. Алгоритм t-SNE представлен в алгоритме 7.

Algorithm 7 t-Distributed Stochastic Neighbour Embedding (t-SNE)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы сходства P между объектами

Шаг 2: Вычисление матрицы сходства Q между объектами в пространстве меньшей размерности

Шаг 3: Минимизация функции стоимости D_{KL} с помощью градиентного спуска **return** Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

2.3.2 Использование расстояния Минковского

Повышение качества кластеризации данных большой размерности можно достичь с помощью использования более чувствительной метрики расстояния, например, Минковского:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}. \quad (2)$$

Согласно исследованиям проблемы «проклятия размерности», связанных с применением различных метрик расстояния [1], были получены результаты, что расстояние Минковского может быть адаптирована для алгоритма k-Means и

при различных значениях параметра p качество кластеризации может значительно возрастать. Одним из способов усовершенствования данного подхода – взвешивание признаков (feature weighting) в метрике Минковского:

$$d(x, y) = \left(\sum_{i=1}^n w_i |x_i - y_i|^p \right)^{\frac{1}{p}}, \quad (3)$$

где w_i - вес i признака. Вес признака может быть получен из разброса данных, в качестве применения алгоритма PCA или методов машинного обучения. Применение взвешенной метрики Минковского предоставляет мощный инструмент для решения проблемы низкого качества кластеризации в пространстве большой размерности благодаря учету важности признаков.

2.3.3 Кластеризация с частичным привлечением учителя

Одним из способов решить проблему снижения качества кластеризации данных большой размерности является помощь алгоритму кластеризации небольшим числом данных с заранее определенными кластерами (таргетами). Кластеризация с частичным привлечением учителя (Semi-supervised clustering) – это подход, использующий комбинацию размеченных (данные с известными кластерами) и неразмеченных (данные, кластера которых неизвестны) данных для улучшения результатов кластеризации. Этот подход позволяет добавить контроль в процесс кластеризации, что приводит к созданию различных кластеров с более четкой структурой, а также добавляет возможность использовать стандартные методы оценки качества результатов алгоритма, такие как точность (Accuracy), прецизионность (Precision) полнота (Recall). Среди алгоритмов кластеризации с частичным привлечением учителя можно выделить основные подходы использования ограниченного знания о классах исходных данных.

Привлечение учителя для генерации начальных кластеров Подход кластеризации с частичным привлечением учителя для генерации начального разбиения на кластеры (seeding) [5], [3] – это метод, в котором небольшой набор

маркированных точек данных используют для формирования начальных кластеров, таким образом предоставляя алгоритму хорошую стартовую точку для оптимизационной задачи. В дальнейшем алгоритм кластеризации уже без учителя распространит начальные метки на оставшиеся немаркированные данные на основе мер схожести, обеспечивая сильное влияние начального приближения на весь процесс обучения.

Привлечение учителя для определения принадлежности к кластеру Одним из способов внести знания о кластерах в процесс обучения также является привлечение учителя для определения принадлежности к кластеру. Метод Semi-supervised clustering under a «compact-cluster» assumption [12], который основан на допущении идеи компактности кластеров и минимизирует внутрикластерные расстояния, одновременно максимизируя межкластерные расстояния, обеспечивает четкость и компактность кластеров.

3 Постановка проблемы

3.1 Основные обозначения

В дальнейшем будут использоваться следующие основные обозначения. Пусть $X = \begin{pmatrix} x_i^j \end{pmatrix} \in \mathbb{R}^{n \times d}$ обозначает матрицу наблюдений размером $n \times d$, где каждый d -мерный объект $x_i = (x_i^1, x_i^2, \dots, x_i^d) \in \mathbb{R}^{1 \times d}$ представляет собой строковый вектор признаков для каждого наблюдения $i = 1, 2, \dots, n$. Вектор $x_j = (x_1^j, x_2^j, \dots, x_n^j)^\top \in \mathbb{R}^{n \times 1}$ означает столбец значений признака j для всех наблюдений $j = 1, 2, \dots, d$. Вектор $y = (y_1, y_2, \dots, y_n)^\top \in \mathbb{R}^{n \times 1}$ содержит значения целевой функции, представляющей искомые кластеры. Число кластеров обозначено как k , а разбиение наблюдений на кластеры — как $S = S_1, S_2, \dots, S_k$, где каждый кластер $S_l \subset 1, 2, \dots, n$ для $l = 1, 2, \dots, k$. Набор из k центров кластеров представлен через $c = c_1, c_2, \dots, c_k$, где каждый центр $c_l = (c_l^1, c_l^2, \dots, c_l^d) \in \mathbb{R}^{1 \times d}$ для $l = 1, 2, \dots, k$. Также используется диагональная матрица размерности d , обозначенная как I_d .

3.2 Формулирование задачи кластеризации без учителя

Задача кластеризации относится к типу задач «без учителя» (Unsupervised learning). Задача кластеризации – есть группировка объектов в наборы (группы), основываясь только на их сходстве между собой так, чтобы объекты внутри одной группы были больше похожи на представителей этой группы, чем другой.

Формальная запись задач имеет следующий вид: Для каждого d -мерного объекта x_i из множества объектов $X = x_1, x_2, \dots, x_n$, необходимо поставить в соответствие один из k кластеров $c = \{c_1, c_2, \dots, c_k\}$.

Для оценивания «схожести» объектов могут быть использованы разные метрики расстояния такие как Евклидово расстояние [17], Манхеттенское расстояние, [15], расстояние Минковского [1] и другие. А также различные способы оценки межкластерных расстояний, такие как Average Linkage [26], Complete

Linkage [8], Single Linkage [21].

Задача кластеризации на основе центроидов для расстояния Минковского с параметром p есть задача сложной невыпуклой оптимизации функционала качества (4), которая может быть решена с помощью эвристического алгоритма k-Means для метрики Минковского, где необходимо оптимизировать сумму расстояний между объектами внутри кластеров.

$$\begin{aligned} W_p(S; c) &= \sum_{l=1}^k \sum_{x \in S_l} \sum_{j=1}^d |x^j - c_l^j|^p \rightarrow \min, \\ x &= (x^1, x^2, \dots, x^d) \in R^{1 \times d}, \\ c_l &= (c_l^1, c_l^2, \dots, c_l^d) \in R^{1 \times d} \end{aligned} \tag{4}$$

3.3 Формулирование задачи обучения с учителем

В отличие от задачи кластеризации без учителя, в задаче кластеризации с учителем имеется доступ к части размеченных данных.

Формальная запись задач имеет следующий вид: Дано множество d -мерных объектов $X = \{x_1, x_2, \dots, x_n\}$ и множество меток $\{t_1, t_2, t_3, \dots, t_r\} = T \subset X$ для r объектов, что $r \leq n$. Целью является разделение этого множества на k кластеров $c = \{c_1, c_2, \dots, c_k\}$ таким образом, чтобы объекты внутри каждого кластера принадлежали к одному и тому же классу, при условии, что эти классы известны. Функционал качества кластеризации в этом случае может включать в себя как внутрикластерные, так и межкластерные расстояния, а также дополнительные условия на основе разметки классов.

3.3.1 Выбор метода кластеризации

В данной работе основой для алгоритма кластеризации с учителем служит реализация k-Means с метрикой Минковского для пространств большой размерности, поскольку k-Means – легко интерпретируемый подход, основанный на оптимизации суммарного квадратичного отклонения внутри кластеров. Выбор

k-Means также обусловлен его основными преимуществами: простотой реализации (существует большое число реализаций и оптимизаций данного подхода), высокой скоростью работы (на небольших наборах данных алгоритм способен сходиться за очень короткое время). Алгоритм k-Means выполняет кластеризацию данных, оптимизируя суммарное квадратичное отклонение внутри кластеров. Его работа состоит из нескольких этапов:

1. Инициализация. Фиксируется параметр k – число кластеров, которые необходимо найти, после чего центроиды кластеров выбираются случайным образом.
2. Присвоение данных кластерам. Каждый объект данных присваивается кластеру, чей центроид на основе выбранной метрики расстояния окажется ближе всего.
3. Обновление центроидов. Центроиды пересчитываются на основе объектов из соответствующих кластеров.
4. Итеративное повторение шагов 1, 2 и 3.

3.3.2 Выбор метрики качества

Для оценки качества предложенного алгоритма кластеризации были выбраны метрики *Accuracy*, *NMI*, *ARI*, *AMI*.

Rand Index (RI) является метрикой, используемой для измерения сходства между двумя различными кластеризациями или разбиениями одного и того же набора данных. Основная идея RI заключается в том, чтобы подсчитать долю пар объектов, которые находятся в одном и том же кластере в обоих разбиениях (кластеризациях). Для того чтобы определить RI , вводятся следующие обозначения. Пусть X – набор, состоящий из n объектов для кластеризации, в котором a пар объектов попали в один кластер, а b пар попали в разные кластеры. Тогда

метрика Rand Index (RI) будет иметь вид:

$$RI = \frac{a + b}{C_2^n}. \quad (5)$$

Adjusted Rand Index (ARI) – скорректированная версия Rand Index, предназначенная для измерения сходства между двумя кластеризациями, путем корректировки метрики RI . ARI может принимать значения в промежутке $[0; 1]$, где значение 1 соответствует идентичным кластеризациям, а значение 0 означает, что кластеризации случайны.

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}, \quad (6)$$

где $E[RI]$ – оценка математического ожидания RI , а $\max(RI)$ – максимальное значение Rand Index, полученное в результате кластеризаций.

Mutual Information (MI) измеряет степени зависимости между двумя различными разбиениями одного и того же набора данных на кластеры. Обозначим за U и V два разбиения набора данных X , состоящего из n объектов, что $|U_i|$ – есть количество объектов в кластере U_i , а $|V_j|$ в кластере V_j . Обозначим энтропию за $H(U)$.

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{n} \log \frac{n|U_i \cap V_j|}{|U_i||V_j|}, \quad (7)$$

Normalized Mutual Information (NMI) – вариант MI , который нормализуется для того, чтобы значения можно было интерпретировать на отрезке от 0 до 1. Метрика используется для измерения сходства между двумя различными разбиениями одного и того же набора данных на кластеры.

$$NMI(U, V) = \frac{MI(U, V)}{\text{mean}(H(U), H(V))}. \quad (8)$$

Adjusted Mutual Information (AMI) нормализуется относительно максимальной величины, которую может принять взаимная информация, что позволяет

оценивать сходство между разбиениями на независимых от размера кластеров данных. Она принимает значения в интервале от 0 до 1, где значение 1 означает идентичные разбиения, а значение 0 указывает на полное отсутствие сходства. Данная метрика широко используется в оценке качества различных методов кластеризации или сегментации данных, особенно когда требуется оценить сходство результатов, полученных из разных экспериментов или алгоритмов кластеризации.

$$AMI(U, V) = \frac{MI(U, V) - E[MI(U, V)]}{mean(H(U), H(V)) - E[MI(U, V)]}. \quad (9)$$

Accuracy используется для оценки качества классификации, рассматривая степень совпадения найденных и референтных значений. Для оценки качества кластеризации без учителя использование Accuracy может не давать корректных результатов, так как она опирается только на номера меток, которые в кластеризации могут различаться из-за различной нумерации кластеров. Однако при использовании подхода кластеризации с частичным привлечением учителя, где порядок нумерации кластеров совпадает с референтными значениями, данная метрика отражает насколько точно разделяются объекты на кластеры (классы).

4 Предложенный метод

Одним из способов повышения точности алгоритма кластеризации на основе центроидов для метрики Минковского является частичное привлечение учителя. В данной работе предлагается два способа введения информации о метках в алгоритм кластеризации.

4.1 «Мягкое» привлечение учителя

Мягкое привлечение учителя в задачу кластеризации (Soft semi-supervised clustering) – подход, предлагающий использовать информацию о метках в обучаемом наборе данных для генерации начальных центров вместо выбора их случайным методом. Для расчета начальных центроидов используется алгоритм (8), где каждый центроид высчитывается на основе размеченных объектов. Данный подход позволяет задать начальное приближение задачи оптимизации (4), которая в дальнейшем решается алгоритмом k-Means для метрики Минковского.

Algorithm 8 Выбор начальных центроидов с частичным привлечением учителя

k : Количество классов

X : Множество объектов

Y : Множество меток

Выбрать случайным образом k центров кластеров из X

for кластер $i \in \{1, 2, \dots, k\}$ **do**

 выбрать все точки x из X , у которых есть метки в Y равные k

 вычислить центроид c_i на основе выбранных точек

end for

4.2 «Жесткое» привлечение учителя

Жесткое привлечение учителя в задачу кластеризации (Hard semi-supervised clustering) – подход, предлагающий расширить использование информации о

метках в обучаемом наборе данных. В данном подходе предлагается использовать начальное приближение из алгоритма (8), а также «фиксировать» объекты с известными метками в их кластерах, фактически запрещая переходы объектов из одного кластера в другой, что влияет как на точность, так и на скорость схождения алгоритма.

Algorithm 9 Выбор оптимального кластера для объекта

x : объект

$T = \{t_1, t_2, \dots, t_r\}$: Множество меток для r объектов

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

if T содержит метку t для объекта x **then**

 присвоить объект x кластеру C_t

else

 вычислить d_l - расстояние до каждого центра $c_l \in c$

 присвоить объект x к ближайшему кластеру из C

end if

4.3 Алгоритм k-Means с метрикой Минковского и частичным привлечением учителя

Таким образом, алгоритм кластеризации с метрикой Минковского и частичным привлечением учителя имеет следующий вид.

Algorithm 10 k-Means с метрикой Минковского и частичным привлечением учителя

k : Количество классов

X : Множество объектов

$T = \{t_1, t_2, \dots, t_r\}$: Множество меток для r объектов

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

Выбрать начальное разбиение с помощью алгоритма (8)

while центры не стабилизировались **do**

for точка $x \in X$ **do**

 присвоить x оптимальному кластеру согласно алгоритму (9)

end for

for кластер $C_i \in C$ и центр $c_i \in c$ **do**

 пересчитать центр c_i кластера как среднее значение из точек внутри кластера C_i

end for

end while

Алгоритм был реализован при использовании языка программирования Python 3.10 и библиотеки *numpy* (1.24.3), *scikit-learn* (1.2.0), *scipy* (1.10.0), *umap-learn*==0.5.7. Для анализа результатов была разработана система автоматической генерации таблиц и графиков с использованием библиотеки *pandas* (1.5.2) и *matplotlib* (3.6.2). Для анализа качества алгоритма была разработана система автоматического анализа кода и тестирования алгоритма на платформе GitHub Actions. Качество кода проверялось с использованием библиотек *pylint* (2.15.9) и *isort* (5.11.4). Для тестирования алгоритма были разработаны 168 Unit тестов с использованием библиотеки *pytest* (7.2.0).

5 Заключение

В работе предлагаются и сравниваются два подхода введения учителя в процесс кластеризации k-Means для метрики Минковского для пространств большой размерности *SoftSSLKMeans* и *HardSSLKMeans*. *SoftSSLKMeans* использует идею введения учителя для генерации начального разбиения размеченных объектов на кластеры. *HardSSLKMeans* фиксирует метки размеченных объектов и не дает им сменить кластер в процессе решения задачи оптимизации. Оба алгоритма показывают значительно лучшие результаты в сравнении с алгоритмом k-Means без учителя. В частности, на 3 кластерах *SoftSSLKMeans* с 20% размеченными данными в среднем превосходит k-Means на 74.18%, *HardSSLKMeans* с 20% размеченными данными в среднем превосходит k-Means на 53.56%. На 2 кластерах *HardSSLKMeans* с 15% размеченными данными в среднем превосходит k-Means на 57%. Исследование выполнено с использованием суперкомпьютерного комплекса НИУ ВШЭ [16]. Код проекта доступен по ссылке github.com/alexgiving/LKMeans.

Список литературы

- [1] C. C. Aggarwal, A. Hinneburg, and D. A. Keim, “On the surprising behavior of distance metrics in high dimensional spaces,” in *Proceedings of the 8th International Conference on Database Theory*, ser. ICDT '01. Berlin, Heidelberg: Springer-Verlag, 2001, p. 420–434.
- [2] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander, “Optics: Ordering points to identify the clustering structure,” *SIGMOD Rec.*, vol. 28, no. 2, p. 49–60, jun 1999. [Online]. Available: <https://doi.org/10.1145/304181.304187>
- [3] V. Antoine, N. Labroche, and V.-V. Vu, “Evidential seed-based semi-supervised clustering,” in *2014 Joint 7th International Conference on Soft Computing and Intelligent Systems (SCIS) and 15th International Symposium on Advanced Intelligent Systems (ISIS)*, 2014, pp. 706–711.
- [4] D. Arthur and S. Vassilvitskii, “k-means++: the advantages of careful seeding,” in *SODA '07: Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 2007, pp. 1027–1035.
- [5] S. Basu, A. Banerjee, and R. J. Mooney, “Semi-supervised clustering by seeding,” in *Proceedings of the Nineteenth International Conference on Machine Learning*, ser. ICML '02. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2002, p. 27–34.
- [6] R. Bellman, *Dynamic Programming*, 1st ed. Princeton, NJ, USA: Princeton University Press, 1957.
- [7] R. Cordeiro de Amorim and B. Mirkin, “Minkowski metric, feature weighting and anomalous cluster initializing in k-means clustering,” *Pattern Recognition*, vol. 45, no. 3, pp. 1061–1075, 2012. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320311003517>

- [8] D. Defays, “An efficient algorithm for a complete link method,” *The Computer Journal*, vol. 20, no. 4, pp. 364–366, 01 1977. [Online]. Available: <https://doi.org/10.1093/comjnl/20.4.364>
- [9] A. Demidovskij, A. Tugaryov, A. Trutnev, M. Kazyulina, I. Salnikov, and S. Pavlov, “Lightweight and elegant data reduction strategies for training acceleration of convolutional neural networks,” *Mathematics*, vol. 11, no. 14, 2023. [Online]. Available: <https://www.mdpi.com/2227-7390/11/14/3120>
- [10] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, ser. KDD’96. AAAI Press, 1996, p. 226–231.
- [11] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, “Array programming with NumPy,” *Nature*, vol. 585, no. 7825, pp. 357–362, Sept. 2020. [Online]. Available: <https://doi.org/10.1038/s41586-020-2649-2>
- [12] Z. Jiang, Y. Zhan, Q. Mao, and Y. Du, “Semi-supervised clustering under a “compact-cluster” assumption,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 5, pp. 5244–5256, 2023.
- [13] I. Jolliffe, *Principal Component Analysis*. Springer Verlag, 1986.
- [14] L. Kaufman and P. Rousseeuw, *Finding Groups in Data: An Introduction To Cluster Analysis*, 01 1990.
- [15] L. Kaufman and P. J. Rousseeuw, *Partitioning Around Medoids (Program*

- PAM). John Wiley & Sons, Inc., 2008, pp. 68–125. [Online]. Available: <http://dx.doi.org/10.1002/9780470316801.ch2>
- [16] P. Kostenetskiy, R. Chulkevich, and V. Kozyrev, “Hpc resources of the higher school of economics,” *Journal of Physics: Conference Series*, vol. 1740, p. 012050, 01 2021.
- [17] S. Lloyd, “Least squares quantization in pcm,” *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [18] L. McInnes, J. Healy, N. Saul, and L. Großberger, “Umap: Uniform manifold approximation and projection,” *Journal of Open Source Software*, vol. 3, no. 29, p. 861, 2018. [Online]. Available: <https://doi.org/10.21105/joss.00861>
- [19] F. Murtagh and P. Legendre, “Ward’s hierarchical agglomerative clustering method: Which algorithms implement ward’s criterion?” *Journal of Classification*, vol. 31, no. 3, pp. 274–295, Oct 2014. [Online]. Available: <https://doi.org/10.1007/s00357-014-9161-z>
- [20] S. Setyaningsih, “Using cluster analysis study to examine the successful performance entrepreneur in indonesia,” *Procedia Economics and Finance*, vol. 4, pp. 286–298, 2012, international Conference on Small and Medium Enterprises Development with a Theme ?Innovation and Sustainability in SME Development? (ICSMED 2012). [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2212567112003437>
- [21] R. Sibson, “SLINK: An optimally efficient algorithm for the single-link cluster method,” *The Computer Journal*, vol. 16, no. 1, pp. 30–34, 01 1973. [Online]. Available: <https://doi.org/10.1093/comjnl/16.1.30>
- [22] B. Sorscher, R. Geirhos, S. Shekhar, S. Ganguli, and A. Morcos, “Beyond neural scaling laws: beating power law scaling via data pruning,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal,

D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 19 523–19 536.

- [23] L. van der Maaten and G. Hinton, “Visualizing data using t-sne,” *Journal of Machine Learning Research*, vol. 9, no. 86, pp. 2579–2605, 2008. [Online]. Available: <http://jmlr.org/papers/v9/vandermaaten08a.html>
- [24] G. Van Rossum and F. L. Drake, *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace, 2009.
- [25] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, S. J. van der Walt, M. Brett, J. Wilson, K. J. Millman, N. Mayorov, A. R. J. Nelson, E. Jones, R. Kern, E. Larson, C. J. Carey, Í. Polat, Y. Feng, E. W. Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, E. A. Quintero, C. R. Harris, A. M. Archibald, A. H. Ribeiro, F. Pedregosa, P. van Mulbregt, and SciPy 1.0 Contributors, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [26] N. Xu, R. B. Finkelman, S. Dai, C. Xu, and M. Peng, “Average linkage hierarchical clustering algorithm for determining the relationships between elements in coal,” *ACS Omega*, vol. 6, no. 9, pp. 6206–6217, 2021, pMID: 33718711. [Online]. Available: <https://doi.org/10.1021/acsomega.0c05758>