

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки магистров по направлению

01.04.02 Прикладная математика и информатика

ОТЧЕТ
по учебной практике

Проверили:

Д-р физико-математических
наук, проф. В.А. Калягин

Доцент. Е.К. Бацына

Выполнил:

Студент гр. 23 МАГИАД
Трутнев Алексей Игоревич

Нижний Новгород, 2025

Содержание

1	Введение	3
2	Содержательная часть	5
2.1	Краткая характеристика организации	5
2.2	Описание профессиональных задач	5
3	Исполненное индивидуальное задание	6
3.1	Разработка алгоритма	6
3.2	Экспериментальное сравнение методов	9
3.2.1	Эксперименты на синтетических данных	10
3.2.2	Эксперименты на реальных данных	18
4	Заключение	24

1 Введение

В современную эпоху экспоненциального роста объёмов информации, производимой в самых различных сферах — от академической науки и банковских операций до повседневной активности пользователей в цифровой среде — возрастает потребность не просто в хранении данных, но в их осмыслении. Именно в этом контексте критически важной становится задача систематизации и выявления скрытых закономерностей в массиве информации. Одним из наиболее действенных инструментов такого анализа выступает кластеризация — процесс, в ходе которого объекты группируются в кластеры, где элементы внутри группы обладают высокой степенью сходства, а между кластерами — существенными различиями.

Кластеризация принадлежит к категории методов обучения без учителя в рамках машинного обучения, что делает её особенно ценной в ситуациях, когда отсутствуют заранее определённые метки классов или чёткие категории. В отличие от классификации, где алгоритм обучается на размеченных данных, кластеризация исследует структуру данных самостоятельно. Это превращает её в незаменимый инструмент первичного анализа, особенно при работе с неструктурированными наборами данных.

Применение кластеризации охватывает широкий спектр дисциплин и индустрий. В биоинформатике, например, её алгоритмы применяются для анализа экспрессии генов, помогая выделять группы с аналогичными биологическими свойствами. В сфере маркетинга и потребительской аналитики кластеризация позволяет делить аудиторию на сегменты по поведенческим и географическим признакам — что, в свою очередь, оптимизирует маркетинговые стратегии. В задачах информационного поиска она помогает сортировать документы по темам, бороться со спамом и упрощать навигацию в огромных текстовых хранилищах. А в социальной аналитике — выявлять сообщества, изучать паттерны общения и взаимодействия между пользователями.

С математической точки зрения, кластеризация — это не просто абстрактное деление объектов, а сложная задача, включающая выбор подходящей метрики расстояния, определение оптимального числа кластеров (в случае, скажем, метода k -Means) и интерпретацию полученной структуры. Существует множество техник: от иерархической кластеризации до алгоритмов, ориентированных на плотность распределения точек (например, DBSCAN) или вероятностные модели, такие как ЕМ-алгоритм. Каждая из них обладает со своими сильными и слабыми сторонами. Потому выбор конкретного метода всегда требует учета специфики данных и целей анализа.

Тем не менее, несмотря на широкую применимость, методы кластеризации не лишены ограничений. Одним из наиболее острых среди них является проклятие размерности — феномен, при котором эффективность алгоритмов резко падает с увеличением числа признаков. В многомерных пространствах, где число измерений значительно превышает количество наблюдаемых объектов, метрики расстояний становятся всё менее информативными: точки оказываются почти равноудалёнными друг от друга, различия между ними теряются. В результате — данные становятся разреженными, а такие методы, как k -Means, теряют свою разделяющую способность. Более того, интерпретация результатов усложняется, алгоритмы становятся подверженными переобучению, а чувствительность к шуму и выбросам возрастает.

Чтобы противостоять этому эффекту, широко применяются методы предварительного снижения размерности. Такие алгоритмы позволяют спроецировать данные в пространство меньшей размерности, сохранив при этом наиболее значимые структурные особенности. Однако вопрос о том, какой из методов выбрать и как это повлияет на результат кластеризации, остаётся открытым и требует дополнительного теоретического и эмпирического анализа.

Целью прохождения учебной практики являлось исследование влияния методов предварительного снижения размерности на качество кластеризации в пространствах большой размерности.

Для достижения данной цели поставлены следующие задачи:

1. разработать алгоритм кластеризации предварительным применением методов снижения размерности,
2. провести экспериментальное сравнение методов снижения размерности на различных наборах данных,
3. проанализировать влияния методов снижения размерности на качество кластеризации.

2 Содержательная часть

2.1 Краткая характеристика организации

Практика проходила в Научном Исследовательском Университете Высшая Школа Экономики (НИУ ВШЭ), кафедра «Прикладной Математики и Информатики» (ПМИ) – Нижний Новгород.

Сфера деятельности. Деятельность НИУ ВШЭ каф. ПМИ направлена подготовку высококвалифицированных специалистов по направлению «Прикладная математика и информатика», обладающих знаниями и квалификацией, необходимыми для профессионального моделирования и информационного обеспечения экономических и бизнес процессов, анализа и обработки данных.

Организационная структура. Заведующий кафедрой – профессор Калягин Валерий Александрович.

2.2 Описание профессиональных задач

На практике были поставлены следующие профессиональные задачи:

1. разработать алгоритм кластеризации предварительным применением методов снижения размерности,
2. провести экспериментальное сравнение методов снижения размерности на различных наборах данных,
3. проанализировать влияния методов снижения размерности на качество кластеризации.

3 Исполненное индивидуальное задание

В рамках индивидуального задания была выполнена следующая работа:

1. разработан алгоритм применения методов снижения размерности в качестве этапа предобработки данных для кластеризации в пространствах большой размерности,
2. проведено экспериментальное сравнение методов снижения размерности на различных наборах данных,
3. проанализировано влияния методов снижения размерности на качество кластеризации.

3.1 Разработка алгоритма

Алгоритм k -Means — один из самых интуитивно понятных и широко используемых методов кластеризации, благодаря своей простоте реализации и высокой скорости работы на больших объёмах данных. Его основная идея заключается в том, чтобы разбить множество объектов на заданное число кластеров таким образом, чтобы каждый элемент принадлежал группе с ближайшим к нему центром. Однако за внешней очевидностью скрываются и определённые уязвимости. Прежде всего, k -Means демонстрирует высокую чувствительность

к инициализации — начальные позиции центров кластеров могут существенно повлиять на итоговую структуру разбиения. Это означает, что одни и те же данные, обработанные несколько раз с разными начальными условиями, могут привести к разным результатам. Кроме того, алгоритм предполагает, что кластеры имеют сферическую форму и примерно одинаковые размеры, что далеко не всегда соответствует реальному положению дел. В случае с нелинейно разделимыми данными или кластерами сложной геометрии, эффективность метода резко снижается.

В рамках индивидуального проекта была реализована модификация классического подхода, направленная на устранение одного из ключевых ограничений — его неспособности эффективно работать в условиях высокой размерности признакового пространства. Для этого в архитектуру алгоритма был добавлен предварительный этап — снижение размерности входных данных перед выполнением кластеризации (алгоритм 1). Такой шаг позволяет не только уменьшить вычислительную сложность задачи, но и повысить устойчивость итоговых кластеров за счёт устранения шумовых и избыточных признаков.

Algorithm 1 Кластеризация с предварительным снижением размерности

k : Количество классов

X : Множество объектов

d_{target} : Размерность пространства, в котором будет производиться кластеризация

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

$Processor()$: Выбранный метод снижения размерности

$X_{d_{target}} \leftarrow Processor(X, d_{target})$ - применить метод снижения размерности в пространство размерности d_{target} для данных X

Выбрать случайным образом k центров кластеров из $X_{d_{target}}$

while центры не стабилизировались **do**

for точка $x \in X$ **do**

 вычислить расстояние до каждого центра c

 присвоить x кластеру с ближайшим центром кластера

end for

for кластер $C_i \in C$ и центр $c_i \in c$ **do**

 пересчитать центр c_i кластера как среднее значение из точек внутри кластера C_i

end for

end while

В качестве методов снижения размерности были исследованы следующие методы:

- Locally Linear Embedding (LLE),
- Multidimensional Scaling (MDS),
- Principal Component Analysis (PCA),
- Spectral Embeddings (SE),
- Uniform Manifold Approximation and Projection (UMAP).

3.2 Экспериментальное сравнение методов

Алгоритм k -Means демонстрирует наилучшие результаты в тех случаях, когда данные обладают рядом специфических характеристик, создающих благоприятные условия для корректной работы метода. Прежде всего, речь идёт о сферической структуре кластеров: каждый кластер должен быть приблизительно симметричным относительно своего центра, а расстояния от центроидов до границ кластера — примерно одинаковыми. Такая конфигурация обеспечивает чёткую геометрическую интерпретацию центров масс и минимизирует ошибки при расчёте евклидовых расстояний. Не менее важным фактором является сходная плотность данных внутри кластеров. В тех случаях, когда плотность одной группы объектов значительно превышает плотность другой, k -Means может ошибочно объединить разреженные участки или, наоборот, раздробить плотную область на несколько частей. Алгоритм также чувствителен к степени разделённости кластеров: чем больше расстояние между группами по сравнению с их внутренним разбросом, тем выше вероятность корректного выделения кластеров. Последнее, но не менее значимое условие — однородность размеров кластеров. k -Means предпочитает, чтобы кластеры были схожи по объёму и радиусу, иначе велик риск, что объекты меньшего кластера окажутся «поглощёнными» более крупным.

С целью получения надежных и воспроизводимых оценок качества кластеризации, результаты проводимых экспериментов были усреднены по 100 независимым запускам алгоритма, каждый из которых начинался с различной инициализации. Такой подход позволяет сгладить влияние случайных факторов, повысить статистическую значимость выводов и оценить стабильность найденных решений.

3.2.1 Эксперименты на синтетических данных

В данной главе рассматриваются синтетические наборы, состоящие из смесей нормальных распределений с фиксированным Σ и μ . Плотность смеси нормальных распределений:

$$f(x) = \sum_{l=1}^k p_l f_l(x), \quad x = (x^1, x^2, \dots, x^d), p_l > 0, \sum_{l=1}^k p_l = 1.$$

Для синтетических наборов данных матрицы ковариаций фиксируются как единичные диагональные матрицы $\Sigma = I_d$. С помощью параметра t математические ожидания распределений могут быть сближены или разнесены по правилу:

$$\mu_i(t) = \mu_i + t\left(\frac{\sum_{j=1}^k \mu_j}{k} - \mu_i\right), \quad 0 \leq t \leq 1, \forall i \in [1, k].$$

Для синтетического набора, состоящего из смеси 2 нормальных распределений, заданы математические ожидания по правилу:

$$\mu_1 = (-4, 0, 0, \dots)$$

$$\mu_2 = (4, 0, 0, \dots).$$

Анализ поведения методов снижения кластеризации при снижении числа компонент. В данной части экспериментов исследуется влияние методов снижения размерности на поведение алгоритма кластеризации k -Means в условиях идеализированной структуры данных. Используемые синтетические выборки построены как смеси нормальных распределений с заранее заданными параметрами: идентичной дисперсией ($\Sigma = I_d$), равновесными априорными вероятностями кластеров и симметрично расположенными центрами μ_1 и μ_2 . Это обеспечивает выполнение всех условий, благоприятных для работы алгоритма k -Means: сферичность кластеров, равную плотность и размер, а также чёткое разделение между группами при $t < 0$. Таким образом, снижение размерности становится единственным фактором, искажающим исходную структуру данных.

Целью эксперимента является оценка того, насколько каждый из методов снижения размерности способен сохранить делимость между кластерами при поэтапном сокращении размерности пространства от исходной размерности (20) до экстремально низкой (2).

На рисунке 1 представлены графики зависимости качества кластеризации от числа компонент после снижения размерности при параметре $t = 0.4$, что соответствует умеренному уровню перекрытия между кластерами. Этот сценарий позволяет оценить способность методов сохранять полезную кластерную структуру без избыточной плотности или разреженности данных.

Исходя из графиков, можно выделить явного лидера — метод PCA, который стабильно показывает максимальные значения метрик (порядка 0.9 и выше) при любом количестве оставляемых компонент. Это указывает на эффективное сохранение линейной структуры синтетических данных, особенно в случаях, когда кластеры умеренно разделены. MDS, а также ISOMAP и UMAP, дают сопоставимо высокие результаты, практически не зависящие от количества компонент, что говорит о слабой деградации качества даже при сильном снижении размерности данных. Locally Linear Embeddings и Spectral Embeddings, напротив, демонстрируют выраженную чувствительность к размерности. С уменьшением числа компонент качество кластеризации постепенно улучшается и достигает пика на размерности равной числу заложенных кластеров.




Рис. 1: Анализ влияния размерности данных при различных методах снижения размерности на кластеризацию синтетического набора данных с параметром $t = 0.4$. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 2 представлен анализ влияния количества компонент, оставляемых после снижения размерности, на качество кластеризации при фиксированном значении параметра $t = 0.8$, соответствующем сильному перекрытию кластеров. На этом уровне разделимость между группами минимальна, что делает задачу особенно чувствительной к качеству понижения размерности. Также, следует, что методы PCA демонстрирует наилучшую устойчивость и качество

кластеризации вне зависимости от числа компонент. В противоположность, методы Locally Linear Embeddings и Spectral Embeddings показывают низкие и слабо возрастающие значения всех метрик при уменьшении количества компонент, что говорит о неэффективном представлении кластерной структуры в условиях высокой плотности и перекрытия.

Таким образом, при высоком уровне наложения кластеров (большое t) и варьируемом числе компонент, наиболее стабильные и надёжные результаты обеспечивают методы PCA и MDS. Остальные методы, особенно LLE и Spectral, оказываются крайне чувствительными к размерности и не рекомендованы к применению в таких условиях.



Рис. 2: Анализ влияния размерности данных при различных методах снижения размерности на кластеризацию синтетического набора данных с параметром $t = 0.8$. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

Таким образом, эксперимент подтвердил, что даже в условиях идеальной геометрии кластеров агрессивное снижение размерности способно существенно нарушить пространственную структуру, необходимую для корректной работы k -Means. Наиболее устойчивыми к снижению размерности оказались методы PCA и MDS. Это подчёркивает важность выбора метода снижения размерности в зависимости от допустимой степени искажения данных при сохранении

кластерной структуры.

Анализ поведения методов снижения кластеризации при сближении кластеров. В данной части экспериментов особое внимание уделяется анализу устойчивости и адаптивности различных методов снижения размерности в условиях, когда кластеры в данных становятся всё менее различимыми – то есть постепенно сближаются в пространстве признаков. Синтетическая модель, построенная как смесь нормальных распределений с контролируемым расстоянием между центрами кластеров, позволяет формализованно варьировать степень перекрытия кластеров с помощью параметра t , не изменяя другие характеристики выборки.

В условиях, когда $t < 0$, центры кластеров максимально удаляются друг от друга без пересечений, что соответствует идеальному случаю для алгоритма k -Means. По мере увеличения значения t до 1 центры притягиваются к общему центру масс, и границы между кластерами становятся всё менее чёткими, что моделирует реальные сценарии, в которых классы могут частично перекрываться. Такой подход позволяет объективно оценить, насколько методы понижения размерности сохраняют или теряют разделимость между группами при убывающем межкластерном расстоянии.

Результаты экспериментов продемонстрированы на рисунке 3, и показали высокую степень чувствительности к росту перекрытия кластеров.

При анализе показателей AMI, ARI и NMI можно наблюдать устойчивое превосходство методов MDS, ISOMAP и UMAP на всех значениях параметра t , особенно в областях, где кластеры хорошо разделены ($t < 0.4$). Эти методы демонстрируют почти идеальное восстановление кластерной структуры при низких значениях t , что соответствует высокой степени отделённости кластеров. С увеличением t все методы, за исключением Spectral Embeddings и Locally Linear Embeddings (LLE), относительно стабильно теряют качество, однако сохраняют приемлемый уровень информативности вплоть до $t \approx 0.6$. В то же

время, методы Spectral и LLE показывают значительно худшие показатели на всех интервалах t , демонстрируя явную нестабильность и уязвимость к изменению межкластерного расстояния.

Особенно интересным является пик значений метрик (в районе $t = 0.4$) для Spectral и LLE, что может быть обусловлено локальным улучшением связности графов при частичном сближении кластеров. Однако после этого значения происходит резкое падение метрик, особенно AMI и NMI, указывающее на неспособность этих методов сохранять глобальную структуру данных при сильном перекрытии.

С точки зрения времени выполнения, наиболее ресурсоёмкими методами оказались Spectral Embeddings и ISOMAP, особенно в зонах частичного перекрытия кластеров. Напротив, PCA, MDS и UMAP демонстрируют не только высокое качество кластеризации, но и эффективность по времени, что делает их особенно предпочтительными для задач, требующих баланса между точностью и скоростью.

Таким образом, в условиях постепенно сближающихся кластеров методы MDS, UMAP и ISOMAP оказываются наиболее надёжными как по качеству кластеризации, так и по вычислительным затратам. Методы Spectral и LLE, напротив, показали нестабильное поведение и склонность к деградации качества при увеличении параметра t .




Рис. 3: Анализ влияния различных методов снижения размерности данных на кластеризацию синтетического набора данных при сближении и отдалении центров кластеров. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

Таким образом, анализ на синтетических данных подтвердил, что эффективность методов снижения размерности сильно зависит от геометрии и плотности кластеров. Это подчёркивает необходимость адаптивного выбора метода снижения размерности в зависимости от ожидаемой сложности кластерной структуры в данных.

3.2.2 Эксперименты на реальных данных

Также предложенный подход был исследован на реальных данных. Для этого было решено использовать несколько стандартных наборов данных:

- Breast Cancer,
- Digits,
- Wine.

Результаты алгоритма на наборе данных Breast Cancer. Breast Cancer — это стандартный набор данных для бинарной классификации, часто используемый в задачах медицинской диагностики. Данные содержат результаты измерений опухолей молочной железы, полученные при помощи тонкоигольной аспирационной биопсии (FNA). Каждая запись включает характеристики клеточных ядер, такие как радиус, текстура, периметр и другие морфологические признаки.

Таблица 1: Характеристики набора данных Breast Cancer.

Число классов	Число объектов	Размерность пространства
2	569	30

Набор данных Breast Cancer представляет собой матрицу размерностью 569x30, где каждая строка соответствует отдельному образцу опухоли, а каждый столбец содержит числовое значение одного из диагностических признаков. Целевая переменная указывает на доброкачественность (benign) или злокачественность (malignant) новообразования. Данные часто используются для обучения моделей машинного обучения, направленных на автоматизацию диагностики рака молочной железы.




Рис. 4: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Breast Cancer. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 4 представлены результаты применения различных методов снижения размерности перед кластеризацией K-Means на наборе данных Breast Cancer. Наиболее заметную положительную динамику продемонстрировали методы Locally Linear Embedding (LLE) и Spectral Embedding – при уменьшении размерности до 10 и ниже наблюдается последовательный рост метрик кластеризации: AMI, ARI и NMI. Пиковые значения достигаются в точке, где число

компонент совпадает с числом кластеров в выборке, что может свидетельствовать о более точной структурной декомпозиции, когда размерность пространства отражает истинное количество скрытых групп. В то же время алгоритмы PCA и MDS демонстрируют стабильные показатели качества, близкие к базовому сценарию кластеризации без предварительного снижения размерности. Это указывает на то, что оба метода хорошо сохраняют глобальную структуру данных, которая является ключевой для работы алгоритма K-Means. Особенно стоит отметить MDS, который обеспечивает не только стабильность качества, но и высокую воспроизводимость результатов на всем диапазоне размерностей. Такое поведение подтверждает различия в подходах: методы LLE и Spectral Embedding склонны акцентировать внимание на локальных взаимосвязях между точками, что делает их полезными при сильной редукции, в то время как PCA и MDS сохраняют глобальную топологию, важную для более устойчивой кластеризации.

Результаты алгоритма на наборе данных Digits. Digits — это стандартный набор данных для многоклассовой классификации, часто используемый в задачах распознавания образов. Данные представляют собой рукописные цифры от 0 до 9, оцифрованные в виде изображений 8x8 пикселей. Каждое изображение преобразовано в матрицу чисел, отражающих интенсивность оттенков серого.

Таблица 2: Характеристики набора данных Digits.

Число классов	Число объектов	Размерность пространства
10	1797	64

Набор данных Digits представляет собой матрицу размерностью 1797x64, где каждая строка соответствует одному изображению цифры, а каждый столбец содержит значение яркости пикселя (от 0 до 16). Исходные изображения были нормализованы для уменьшения влияния вариаций наклона и толщины линий.




Рис. 5: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Digits. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 5 представлены результаты экспериментов на датасете Digits. Следует отметить, что из-за ограничений существующей программной реализации методы MDS и Locally Linear Embedding не смогли корректно выполнить процедуру снижения размерности на этом наборе данных и, таким образом, были исключены из анализа. Среди протестированных алгоритмов ярким лидером оказался ISOMAP, который уверенно превзошёл остальные методы по всем

основным метрикам кластеризации — AMI, ARI и NMI. Он продемонстрировал стабильное превосходство над базовой линией (результат кластеризации без снижения размерности) вплоть до размерности в 2 компоненты, что говорит о его способности сохранять глобальную геометрию данных даже в сильно сжатом пространстве. Метод PCA продемонстрировал устойчивую деградацию качества кластеризации при уменьшении числа компонент, особенно заметную ниже порога в 10 компонент. Это отражает его ограниченность в улавливании нелинейных зависимостей в данных. Spectral Embedding, напротив, показал результаты в целом ниже уровня базового k -Means, что может объясняться тем, что он оптимизирует локальные отношения между точками, а не глобальную структуру. Тем не менее, на размерности, равной числу кластеров, наблюдался кратковременный всплеск метрик, что, вероятно, связано с тем, что алгоритм эффективно извлекает локальные кластеры, когда размерность достаточно для сохранения этих структур. Также была выявлена интересная зависимость по времени выполнения: ISOMAP, несмотря на свою сложность, в среднем демонстрировал сравнительно низкое время работы с редкими всплесками, что делает его не только точным, но и потенциально пригодным для практического применения при разумной конфигурации.

Результаты алгоритма на наборе данных Wine. Wine - это стандартный и простой набор данных для многоклассовой классификации. Эти данные являются результатами химического анализа вин, выращенных в одном и том же регионе Италии тремя разными производителями. Существует тринадцать различных измерений, проведенных для различных компонентов, содержащихся в трех сортах вина.

Таблица 3: Характеристики набора данных Wine.

Число классов	Число объектов	Размерность пространства
3	178	13

Набор данных Wine представляет собой матрицу с размерностью 178x13, где каждая строка соответствует отдельному образцу вина, а каждый столбец содержит значение конкретного химического измерения.




Рис. 6: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Wine. Линия Baseline – результат работы алгоритма *k*-Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 6 представлены результаты экспериментов по кластеризации с предварительным снижением размерности на наборе данных Wine. Анализ показал, что методы PCA, ISOMAP и UMAP обеспечивают устойчивое поведе-

ние метрик, оставаясь на уровне или вблизи базовой линии на всем диапазоне компонент. Однако, несмотря на эту стабильность, они не продемонстрировали прироста качества кластеризации при уменьшении размерности. В то же время, методы Locally Linear Embedding (LLE) и Spectral Embedding показали заметное улучшение показателей AMI, ARI и NMI при переходе к малым числам компонент (2–4). Это указывает на их способность извлекать более информативную структуру данных в условиях значительного снижения размерности. Тем не менее, даже при росте метрик, их абсолютные значения остаются ниже по сравнению с другими методами, что ограничивает их практическую эффективность в этом конкретном примере. Важно отметить интересную закономерность: как ISOMAP, так и UMAP демонстрируют снижение качества кластеризации при переходе к размерностям, меньшим, чем реальное количество классов в выборке. Это может быть связано с потерей кластерной структуры, «неукладывающейся» в сжатое пространство. Такая деградация указывает на важность учета семантической емкости признакового пространства при выборе числа компонент. По времени выполнения алгоритма наилучшую стабильность и скорость показали MDS и PCA, что делает их предпочтительными с точки зрения вычислительной эффективности, особенно в сценариях, где время критично.

4 Заключение

В рамках учебной практики все запланированные цели и задачи были успешно реализованы. В частности был разработан и апробирован подход применения алгоритмов снижения размерности как части этапа предобработки данных, проведена серия экспериментов, осуществлен анализ полученных результатов. Полученные на практике результаты будут интегрированы в дипломную работу, что отражает практическую и научную ценность проделанной работы. Таким образом, все задачи учебной практики можно считать выполненными в полном объеме.