

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

Программа подготовки магистров по направлению

01.04.02 Прикладная математика и информатика

Трутнев Алексей Игоревич

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Кластеризация в пространствах большой размерности

Рецензент

должность

ФИО

Научный руководитель

д-р физико-математических

наук, проф.

В.А. Калягин

Нижний Новгород, 2025

Содержание

1	Введение	4
2	Обзор литературы	7
2.1	Введение в кластеризацию	7
2.2	Методы кластеризации	8
2.2.1	Кластеризация на основе центроидов	9
2.2.2	Кластеризация на основе плотности	11
2.2.3	Иерархическая кластеризация	12
2.2.4	Кластеризация на основе обучения Хебба	15
2.3	Проблемы пространства большой размерности	16
2.3.1	Использование расстояния Минковского	17
2.3.2	Кластеризация с частичным привлечением учителя	18
2.3.3	Самоконтролируемая кластеризация	19
2.3.4	Методы снижения размерности	20
3	Постановка проблемы	28
3.1	Основные обозначения	28
3.2	Формулирование задачи кластеризации без учителя	28
3.2.1	Выбор метода кластеризации	29
3.2.2	Выбор метрики качества	30
4	Предложенный метод	32
4.1	Методы снижения размерности	33
5	Результаты исследования	36
5.1	Эксперименты на синтетических данных	37
5.1.1	Анализ поведения методов снижения кластеризации при снижении числа компонент.	38

5.1.2	Анализ поведения методов снижения кластеризации при сближении кластеров.	42
5.2	Эксперименты на реальных данных	45
5.2.1	Результаты алгоритма на наборе данных Breast Cancer. .	45
5.2.2	Результаты алгоритма на наборе данных Digits.	47
5.2.3	Результаты алгоритма на наборе данных Wine.	49
6	Заключение	53
	Список литературы	54

1 Введение

В современную эпоху экспоненциального роста объёмов информации, производимой в самых различных сферах – от академической науки и банковских операций до повседневной активности пользователей в цифровой среде – возрастает потребность не просто в хранении данных, но в их осмыслении. Именно в этом контексте критически важной становится задача систематизации и выявления скрытых закономерностей в массиве информации. Одним из наиболее действенных инструментов такого анализа выступает кластеризация – процесс, в ходе которого объекты группируются в кластеры, где элементы внутри группы обладают высокой степенью сходства, а между кластерами – существенными различиями.

Кластеризация принадлежит к категории методов обучения без учителя в рамках машинного обучения, что делает её особенно ценной в ситуациях, когда отсутствуют заранее определённые метки классов или чёткие категории. В отличие от классификации, где алгоритм обучается на размеченных данных, кластеризация исследует структуру данных самостоятельно. Это превращает её в незаменимый инструмент первичного анализа, особенно при работе с неструктурированными наборами данных.

Применение кластеризации охватывает широкий спектр дисциплин и индустрий. В биоинформатике, например, её алгоритмы применяются для анализа экспрессии генов, помогая выделять группы с аналогичными биологическими свойствами. В сфере маркетинга и потребительской аналитики кластеризация позволяет делить аудиторию на сегменты по поведенческим и географическим признакам – что, в свою очередь, оптимизирует маркетинговые стратегии. В задачах информационного поиска она помогает сортировать документы по темам, бороться со спамом и упрощать навигацию в огромных текстовых хранилищах. А в социальной аналитике – выявлять сообщества, изучать паттерны общения и взаимодействия между пользователями.

С математической точки зрения, кластеризация – это не просто абстрактное деление объектов, а сложная задача, включающая выбор подходящей метрики расстояния, определение оптимального числа кластеров (в случае, скажем, метода k -Means) и интерпретацию полученной структуры. Существует множество техник: от иерархической кластеризации до алгоритмов, ориентированных на плотность распределения точек (например, DBSCAN) или вероятностные модели, такие как ЕМ-алгоритм. Каждая из них обладает со своими сильными и слабыми сторонами. Потому выбор конкретного метода всегда требует учета специфики данных и целей анализа.

Тем не менее, несмотря на широкую применимость, методы кластеризации не лишены ограничений. Одним из наиболее острых среди них является проклятие размерности – феномен, при котором эффективность алгоритмов резко падает с увеличением числа признаков. В многомерных пространствах, где число измерений значительно превышает количество наблюдаемых объектов, метрики расстояний становятся всё менее информативными: точки оказываются почти равноудалёнными друг от друга, различия между ними теряются. В результате – данные становятся разреженными, а такие методы, как k -Means, теряют свою разделяющую способность. Более того, интерпретация результатов усложняется, алгоритмы становятся подверженными переобучению, а чувствительность к шуму и выбросам возрастает.

Чтобы противостоять этому эффекту, широко применяются методы предварительного снижения размерности. Такие алгоритмы позволяют спроецировать данные в пространство меньшей размерности, сохранив при этом наиболее значимые структурные особенности. Методы такие как PCA (Principal Component Analysis), MDS (Multi Dimensional Scaling) и UMAP (Uniform Manifold Approximation and Projection) позволяют сократить пространство признаков при сохранении его ключевой структуры. Однако вопрос о том, какой из методов выбрать и как это повлияет на результат кластеризации, остаётся открытым и требует дополнительного теоретического и эмпирического анализа.

В данной работе рассматривается применение кластеризации с предварительным применением методов снижения размерности и анализ их влияния на качество кластеризации, устойчивости алгоритма и интерпретируемости результатов.

Для достижения данной цели поставлены следующие задачи:

1. систематизировать и проанализировать существующие методы кластеризации, а также методы снижения размерности,
2. реализовать алгоритм кластеризации предварительным применением методов снижения размерности,
3. провести экспериментальное исследование и анализ влияния методов снижения размерности на качество кластеризации,
4. разработать рекомендации по выбору методов снижения размерности в зависимости от характеристик данных и целей кластеризации.

Таким образом, работа направлена на разработку и экспериментальное обоснование стратегии, сочетающей в себе преимущества методов снижения размерности и алгоритма k -Means. Такой подход позволяет не только минимизировать негативные эффекты высокой размерности, но и повысить точность и надёжность кластеризации в условиях больших и сложных наборов данных.

2 Обзор литературы

2.1 Введение в кластеризацию

Кластеризация представляет собой один из фундаментальных методов машинного обучения, используемый для группировки объектов на основе их внутренних признаков и сходства без привлечения учителя, то есть без использования размеченных данных. В отличие от классификации, где объекты распределяются по заранее определённым классам, кластеризация позволяет выявлять скрытые структуры и закономерности в данных, что делает её особенно полезной в ситуациях, когда заранее неизвестно, как должны выглядеть классы или группы.

Кластеризация применяется в широком спектре научных и прикладных задач, охватывая такие области, как анализ данных [39], компьютерное зрение [15], биоинформатика [26], обработка естественного языка [17], а также информационные технологии, социальные науки, медицина и финансовая аналитика. Её основная цель — разделить множество объектов на группы (кластеры) таким образом, чтобы объекты в пределах одного кластера обладали максимальной степенью сходства, в то время как объекты различных кластеров — были существенно различны.

Кластеризация может быть использована для решения различных задач, таких как:

- **Сегментация изображений:** разделение изображения на области схожих пикселей, что позволяет выделить объекты на изображении и улучшить качество последующего анализа.
- **Классификация текстов:** группировка текстовых документов по темам или стилям, что позволяет упростить поиск и анализ информации.
- **Кластеризация пользователей:** сегментация пользователей на группы

схожих интересов и предпочтений, что позволяет персонализировать рекомендации и маркетинговые стратегии.

- **Обнаружение аномалий:** выявление аномальных точек, не принадлежащих ни одному кластеру или попадающих в редкие группы, что может свидетельствовать о мошенничестве, сбоях в оборудовании или ошибках в данных.
- **Разведочный анализ данных (EDA, Exploratory Data Analysis):** выявление скрытых закономерностей и структур в данных, что особенно полезно при работе с новыми или плохо изученными наборами данных.

2.2 Методы кластеризации

Существуют различные подходы к реализации кластеризации, отличающиеся не только алгоритмической природой, но и способностью справляться с различными типами данных и структурами кластеров. В зависимости от метода формирования кластеров можно выделить следующие основные категории:

- **Центроидные методы** — основаны на минимизации расстояний между объектами и центральными точками кластеров (k-средних, k-медиан).
- **Иерархические методы** — формируют древовидную структуру кластеров путём последовательного объединения или разбиения групп (агломерационная и дивизионная кластеризация).
- **Плотностные методы** — строят кластеры как области повышенной плотности объектов (например, DBSCAN, OPTICS).
- **Модельные методы** — предполагают, что данные генерируются из смеси вероятностных распределений (например, ЕМ-алгоритм для гауссовых смесей).

- **Спектральные и графовые методы** — используют спектральные свойства графов и матриц смежности для обнаружения кластеров в данных со сложной топологией.

Каждый из подходов обладает своими достоинствами и ограничениями, что требует осознанного выбора метода в зависимости от конкретных характеристик исследуемых данных: размерности, плотности, формы кластеров и наличия шумов. Далее будут подробно рассмотрены эти методы, включая анализ их применимости, вычислительной сложности и устойчивости к внешним факторам.

2.2.1 Кластеризация на основе центроидов

Кластеризация на основе центроидов (centroid-based clustering) представляет собой один из наиболее интуитивно понятных и широко используемых подходов к группировке данных. Суть данного метода заключается в том, что каждый кластер описывается так называемым центроидом — обобщённым представлением «центра тяжести» данных в пределах соответствующего кластера. Объекты присваиваются к тому или иному кластеру на основе минимизации расстояния до соответствующего центроида.

Наиболее известным и базовым представителем центроидной кластеризации является алгоритм k -Means, впервые подробно описанный в работе Ллойда [29]. Данный алгоритм итеративно обновляет позиции центроидов и перераспределяет объекты между кластерами с целью минимизации внутрикластерной дисперсии — суммарного квадратичного расстояния между объектами и центрами кластеров. Простота реализации и высокая вычислительная эффективность обеспечили k -Means широкое распространение, особенно при работе с большими объемами данных.

Однако классический k -Means обладает рядом существенных ограничений. Во-первых, он чувствителен к начальной инициализации центроидов, что может приводить к сходимости к локальным минимумам. Во-вторых, алгоритм предпо-

лагает заданное заранее число кластеров k , что не всегда возможно определить априори. Кроме того, алгоритм плохо справляется с кластерами, имеющими сложную форму, различную плотность или отличающиеся размерами.

В ответ на указанные ограничения было предложено несколько модификаций. Один из таких подходов — k -Means++ [6], который улучшает этап начальной инициализации центроидов путём применения стохастической стратегии выбора начальных точек. Это повышает стабильность и качество итогового разбиения, особенно при наличии шумов и неоднородности в данных.

Альтернативой, сохраняющей идею центроидного представления, является алгоритм k -Medoids, также известный как PAM (Partitioning Around Medoids) [25]. В отличие от k -Means, где центроиды могут быть абстрактными точками, k -Medoids использует в качестве центров реальные объекты из выборки — медианы. Это повышает устойчивость к выбросам и позволяет использовать произвольные метрики расстояния, включая манхэттенскую, косинусную и др. Однако вычислительная сложность алгоритма существенно выше, особенно при больших объемах данных.

Среди более современных подходов можно выделить CLARANS (Clustering Large Applications based upon RANdomized Search) [35], который комбинирует элементы k -Medoids с методами стохастического поиска и улучшает масштабируемость алгоритма при работе с крупными выборками. В свою очередь, Mini-Batch k -Means [38] адаптирован для обработки потоков данных и масштабных задач за счёт обновления центроидов на основе случайных подвыборок (батчей), что уменьшает требования к памяти и ускоряет обучение.

Несмотря на ограниченность в обнаружении кластеров сложной формы, методы, основанные на центроидах, остаются актуальными благодаря своей простоте, интерпретируемости и высокой вычислительной эффективности. Они особенно полезны в качестве базовых моделей или в составе более сложных гибридных решений, где предварительная кластеризация используется как этап инициализации или предобработки данных.

2.2.2 Кластеризация на основе плотности

Методы кластеризации на основе плотности (density-based clustering) представляют собой эффективный класс алгоритмов, разработанных для выявления кластеров в данных с неоднородной плотностью распределения. Основная идея заключается в том, что кластеры формируются как связные области пространства с высокой плотностью объектов, отделённые друг от друга зонами разреженности. В отличие от методов, основанных на центроидах или иерархической структуре, плотностные алгоритмы способны выделять кластеры произвольной формы, устойчивы к шуму и выбросам, а также не требуют предварительного задания числа кластеров.

Наиболее известным и фундаментальным методом в этой категории является DBSCAN (Density-Based Spatial Clustering of Applications with Noise), предложенный в работе М. Эстера и соавторов [16]. Алгоритм определяет кластеры как максимальные области, содержащие взаимосвязанные точки с плотностью выше заданного порога. Основные параметры алгоритма – радиус окрестности и минимальное число точек в окрестности — определяют, является ли точка ядровой, граничной или шумовой. DBSCAN эффективно справляется с задачами обнаружения кластеров различных форм, но его производительность существенно зависит от корректного выбора параметров, что особенно проблематично при переменной плотности данных.

Для преодоления ограничений DBSCAN в условиях разной плотности кластеров был предложен алгоритм OPTICS (Ordering Points To Identify the Clustering Structure) [4]. В отличие от DBSCAN, OPTICS не производит окончательное разбиение, а строит упорядоченное представление плотности данных, называемое reachability plot. Это позволяет визуально определить плотностные структуры и формировать кластеры постфактум, адаптируясь к локальным особенностям плотности. OPTICS расширяет применимость методов плотностной кластеризации, особенно в случаях с вложенными и слабо выраженными структурами.

Более современным и мощным развитием идей DBSCAN является HDBSCAN (Hierarchical DBSCAN) [31]. Данный алгоритм строит иерархическую дендрограмму на основе плотностной связи между точками, а затем применяет процедуру извлечения стабильных кластеров. Он автоматически определяет оптимальное количество кластеров и значительно лучше справляется с кластерами переменной плотности, при этом наследуя устойчивость DBSCAN к шуму. HDBSCAN также предлагает оценку надежности принадлежности точки к кластеру, что повышает интерпретируемость результатов.

Другим интересным направлением является DENCLUE (DENsity-based CLUstering) [30], использующий ядерные оценки плотности (kernel density estimation) для моделирования распределения данных. Это позволяет формировать кластеры на основе градиентных потоков в плотностном пространстве и обеспечивает гибкую настройку формы и гладкости кластеров. Однако метод требует вычислительно дорогих операций и чувствителен к выбору параметра сглаживания.

Плотностные алгоритмы находят широкое применение в задачах обнаружения аномалий, анализе геопространственных данных, выявлении сообществ в социальных сетях и анализе временных рядов, где традиционные методы центроидного типа или иерархические подходы оказываются неэффективными.

В целом, подходы, основанные на плотности, являются мощными средствами анализа сложных, неструктурированных и шумных данных. Их гибкость и устойчивость делают их незаменимыми в случаях, когда структура кластеров заранее неизвестна и может отличаться высокой степенью нелинейности.

2.2.3 Иерархическая кластеризация

Иерархическая кластеризация представляет собой мощный класс алгоритмов, ориентированных на поэтапное построение структуры вложенных кластеров без необходимости заранее задавать их количество. В отличие от центроидных и плотностных методов, иерархический подход формирует древовидную

структуру, называемую дендрограммой, где каждый уровень отражает определённый этап объединения или разбиения кластеров. Это делает метод особенно полезным для визуального анализа структуры данных и выбора оптимального количества кластеров после завершения обучения.

Существует два основных направления иерархической кластеризации:

- Агломеративная (снизу вверх) стратегия, при которой каждый объект изначально рассматривается как отдельный кластер, и далее происходит последовательное объединение ближайших кластеров вплоть до образования единой группы. Данный подход является наиболее распространённым и практически применимым, особенно в случае умеренных размеров выборки. Одним из самых популярных алгоритмов этой категории является метод Уорда [34], минимизирующий увеличение внутрикластерной дисперсии при каждом объединении.
- Дивизионная (сверху вниз) стратегия, напротив, начинается с единственного кластера, включающего все объекты, и рекурсивно разделяет его на подмножества. Несмотря на высокую концептуальную привлекательность, методы этого типа, например алгоритм, предложенный Кауфманом и Руссо [24], требуют значительно больших вычислительных затрат и применяются реже.

Качество работы иерархической кластеризации в значительной степени зависит от выбора метрики расстояния между кластерами. Существует несколько стратегий, определяющих, как именно измеряется расстояние между группами данных:

Single Linkage (Метод ближнего соседа) Метод ближнего соседа [40] определяет расстояние между кластерами как минимальное расстояние между парой точек из разных кластеров. Он хорошо справляется с кластеризацией вытянутых или нестандартных форм, однако чувствителен к шуму и может приводить

к так называемому «эффекту цепочки» — последовательному объединению разреженных объектов.

Complete Linkage (Метод дальнего соседа) В методе дальнего соседа [14] расстояние между кластерами определяется как максимальное расстояние между точками двух кластеров. Этот подход обеспечивает более компактные и равномерные кластеры, но при этом склонен переоценивать расстояния и может неправомерно разделять вытянутые структуры.

Average Linkage (Метод средней связи) Средняя связь [49] использует среднее значение расстояний между всеми парами точек из двух кластеров. Данный метод обеспечивает баланс между крайними подходами и демонстрирует устойчивость к шуму, но иногда недостаточно точно отражает геометрию данных.

Кроме того, иерархические методы удобны тем, что позволяют динамически выбирать оптимальное число кластеров, обрезая дендрограмму на нужной высоте без необходимости многократного запуска алгоритма. Это особенно ценно в условиях, когда структура данных неизвестна заранее.

Несмотря на высокую интерпретируемость и визуальную наглядность, недостатками иерархических методов являются высокая вычислительная сложность ($O(n^2)$ или выше для большинства реализаций) и невозможность коррекции ошибок: однажды принятые решения о слиянии или разбиении не подлежат пересмотру.

Тем не менее, иерархическая кластеризация остаётся важным инструментом в арсенале анализа данных и активно применяется в биоинформатике, текстовом анализе, социологии, психологии и других дисциплинах, где требуется исследование сложных иерархических структур в выборке.

2.2.4 Кластеризация на основе обучения Хебба

Кластеризация на основе обучения Хебба (Hebbian Learning) представляет биологически вдохновленный метод обучения, основывающийся на фундаментальном принципе нейрофизиологии, сформулированном Дональдом Хеббом в 1949 году [20]. Согласно так называемому правилу Хебба, «нейроны, которые активируются совместно, укрепляют связь между собой» (neurons that fire together, wire together). Эта идея легла в основу адаптивного обучения в искусственных нейронных сетях, а также стала мощным инструментом для кластеризации данных на основе корреляционной близости объектов.

С точки зрения формализации, классическое хеббовское обучение предполагает обновление весов связей по правилу:

$$\Delta w = \eta xy, \quad (1)$$

где x и y — входной и выходной сигналы, w — вес связи между входом и выходом, а η — коэффициент обучения. При многократном предъявлении данных такие схемы обучения приводят к усилению связей между часто совместно активируемыми признаками, что способствует формированию естественных кластеров.

Преимуществом хеббовских методов кластеризации является их биологическая правдоподобность, адаптивность к данным, способность выявлять латентные структуры без строгих априорных предположений о количестве кластеров. Однако они также обладают определёнными ограничениями. Наиболее существенными из них являются чувствительность к параметру обучения, зависимость от порядка предъявления входов, а также необходимость калибровки модели для достижения стабильной сходимости.

Тем не менее, обучение Хебба продолжает рассматриваться как перспективная альтернатива классическим методам кластеризации, особенно в условиях высокой размерности и отсутствия чётких границ между группами данных.

2.3 Проблемы пространства большой размерности

Анализ и кластеризация данных в пространствах высокой размерности остаются актуальными задачами современной науки о данных. По мере увеличения числа признаков (измерений), используемых для описания объектов, традиционные методы анализа, включая алгоритмы кластеризации, начинают сталкиваться с фундаментальными затруднениями. Это явление широко известно как «проклятие размерности» (curse of dimensionality), термин, введённый Ричардом Беллманом в 1957 году в контексте динамического программирования [9].

Вычислительная сложность Одним из наиболее очевидных последствий высокой размерности является экспоненциальный рост вычислительной нагрузки. Многие алгоритмы кластеризации, в частности k -Means, требуют вычисления расстояний между каждым объектом и каждым центроидом на каждой итерации. При этом сложность возрастает линейно по числу измерений и квадратично по числу объектов. В пространствах с тысячами признаков это приводит к существенному увеличению времени работы алгоритмов и ресурсов памяти, ограничивая масштабируемость [46].

Разреженность данных По мере увеличения размерности пространства наблюдается феномен разреженности — большая часть гиперкуба, в котором располагаются данные, оказывается практически пустой. Объекты становятся статистически эквивалентно удалёнными друг от друга, и плотность данных резко падает. Как показано в [10], различия в расстояниях между ближайшими и дальними соседями стремятся к нулю по мере роста размерности, делая евклидову метрику всё менее полезной. Это приводит к затруднениям в определении границ между кластерами, особенно при использовании методов на основе расстояния и плотности (например, DBSCAN).

Снижение эффективности метрик С увеличением размерности традиционные метрики расстояния теряют дискриминационную силу. Евклидово расстояние, косинусная близость и манхэттенская метрика становятся всё менее способными различать объекты, что подрывает эффективность как центроидных, так и иерархических и плотностных методов кластеризации [2]. Это особенно критично для алгоритмов, основанных на ближайших соседях или на построении локальных связей.

2.3.1 Использование расстояния Минковского

Одной из возможных стратегий повышения качества кластеризации в пространствах большой размерности является адаптация метрики расстояния. В этом контексте особое внимание заслуживает расстояние Минковского, которое представляет собой обобщение различных метрических функций:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}. \quad (2)$$

Значения параметра p позволяют интерполировать между манхэттенской ($p = 1$) и евклидовой ($p = 2$) метриками, а при $p \rightarrow \infty$ метрика приближается к максимуму по координатам. Исследования показали, что выбор оптимального значения параметра p может существенно повлиять на эффективность кластеризации в условиях высокой размерности [2]. Особенно перспективным направлением является использование взвешенного расстояния Минковского, где каждый признак имеет индивидуальный вес:

$$d(x, y) = \left(\sum_{i=1}^n w_i |x_i - y_i|^p \right)^{\frac{1}{p}}, \quad (3)$$

где w_i — вес признака i . Эти веса могут быть получены, например, с помощью анализа важности признаков, извлечённой из моделей машинного обучения, либо с использованием разложения главных компонент (РСА). Такой подход

позволяет учитывать разную информативность признаков, что особенно важно в условиях высокой размерности и коррелированных признаков. Практические результаты подтверждают, что взвешенные метрики существенно улучшают устойчивость алгоритмов, таких как k -Means, к шуму и нерелевантным признакам [12].

2.3.2 Кластеризация с частичным привлечением учителя

Другая важная стратегия повышения эффективности кластеризации — это частичное привлечение учителя. Semi-supervised clustering сочетает преимущества обучаемых без учителя методов с ограниченным числом меток классов, что позволяет направлять процесс кластеризации к более интерпретируемым и структурированным результатам. Такой подход используется, например, при наличии априорной информации о небольшом числе объектов, чья принадлежность к кластерам заранее известна. Этот подход позволяет добавить контроль в процесс кластеризации, что приводит к созданию различных кластеров с более четкой структурой, а также добавляет возможность использовать стандартные методы оценки качества результатов алгоритма, такие как точность (Accuracy), прецизионность (Precision) полнота (Recall). Среди алгоритмов кластеризации с частичным привлечением учителя можно выделить основные подходы использования ограниченного знания о классах исходных данных.

Привлечение учителя для генерации начальных кластеров Подход кластеризации с частичным привлечением учителя для генерации начального разбиения на кластеры (seeding) [7], [5] — это метод, в котором небольшой набор маркированных точек данных используют для формирования начальных кластеров, таким образом предоставляя алгоритму хорошую стартовую точку для оптимизационной задачи. В дальнейшем алгоритм кластеризации уже без учителя распространит начальные метки на оставшиеся немаркированные данные на основе мер схожести, обеспечивая сильное влияние начального приближения

на весь процесс обучения.

Привлечение учителя для определения принадлежности к кластеру Одним из способов внести знания о кластерах в процесс обучения также является привлечение учителя для определения принадлежности к кластеру. Метод Semi-supervised clustering under a «compact-cluster» assumption [21], который основан на допущении идеи компактности кластеров и минимизирует внутрикластерные расстояния, одновременно максимизируя межкластерные расстояния, обеспечивает четкость и компактность кластеров.

2.3.3 Самоконтролируемая кластеризация

Самоконтролируемая кластеризация (self-supervised clustering) представляет собой гибридную парадигму, сочетающую принципы самоконтролируемого обучения (self-supervised learning, SSL) с задачей кластеризации. В её основе лежит идея извлечения устойчивых и структурно значимых признаков из неразмеченных данных, которые в дальнейшем могут использоваться для формирования кластеров с высокой интерпретируемостью и разделимостью. SSL зарекомендовал себя как эффективный инструмент предварительного анализа, способный существенно улучшать производительность downstream-задач, включая кластеризацию [18].

SSL представляет собой класс методов, в которых обучающая информация извлекается из самих данных без использования явных меток. В результате обучения создаются эмбединги — векторы признаков, которые можно использовать в задачах сегментации, визуализации и кластеризации.

Таким образом, SSL становится этапом предварительного анализа данных. Одним из таких методов может быть этап снижения размерности, позволяющий компактно представить данные в пространстве с меньшей размерностью, сохранив при этом ключевую топологическую структуру.

2.3.4 Методы снижения размерности

Метод главных компонент (Principal Component Analysis) Метод главных компонент (Principal Component Analysis, PCA) — это один из наиболее известных и широко используемых алгоритмов снижения размерности, предложенный ещё в начале XX века и формализованный в современном виде в классической работе Джоллиффа [23]. PCA позволяет перевести данные из пространства высокой размерности в подпространство меньшей размерности, сохранив при этом максимум возможной дисперсии данных. Важной особенностью метода является его линейная природа, что делает его особенно эффективным для задач, в которых основная информация содержится в линейных комбинациях признаков.

Основная идея PCA заключается в нахождении нового ортонормированного базиса пространства признаков, в котором направления (так называемые главные компоненты) упорядочены по убыванию дисперсии проекций данных. Первые несколько компонентов захватывают наибольшую вариативность данных и используются для проекции исходных точек в пространство меньшей размерности. Это позволяет уменьшить объём хранимой информации, ускорить обучение моделей и устранить мультиколлинеарность. Алгоритм PCA включает следующие этапы:

- Стандартизация признаков (центрация и нормализация).
- Вычисление ковариационной матрицы.
- Вычисление собственных значений и собственных векторов ковариационной матрицы.
- Сортировка собственных векторов по убыванию соответствующих собственных значений.
- Формирование проекционной матрицы из первых k векторов.

- Проецирование исходных данных в новое пространство признаков.

Простота PCA, его высокая вычислительная эффективность и математическая интерпретируемость сделали метод фундаментальным инструментом в таких областях, как:

- обработка изображений (например, сжатие изображений, распознавание лиц [43]),
- биоинформатика (анализ экспрессии генов [36]),
- финансовое моделирование (анализ корреляционных структур рынков),
- кластеризация и визуализация многомерных данных [22].

Однако, несмотря на достоинства, линейность PCA является его ограничением. Метод не способен корректно обрабатывать данные, в которых основная структура отражается в нелинейных зависимостях между признаками.

Метод многомерного шкалирования (Multidimensional Scaling) Метод многомерного шкалирования (Multidimensional Scaling, MDS) — это классический подход к снижению размерности, направленный на сохранение попарных расстояний или близостей между объектами при отображении их в пространство меньшей размерности. В отличие от метода главных компонент (PCA), MDS может использовать любой тип метрик, включая неевклидовы, и поэтому считается более гибким для анализа данных с нелинейной структурой.

MDS был впервые разработан как способ визуализации психологической близости между объектами на основе субъективных оценок [28]. Позднее метод получил широкое распространение в информационных науках, биоинформатике, социальной аналитике, анализе текстов и других дисциплинах, где структура данных может быть выражена через матрицу попарных расстояний. Алгоритм MDS включает несколько этапов:

- Входные данные представляют собой матрицу попарных расстояний D между объектами.
- Сначала вычисляется матрица квадратов попарных расстояний B с помощью формулы $B = -\frac{1}{2}D^2$.
- Затем матрица B центрируется, чтобы устранить влияние глобального смещения и обеспечить корректное представление расстояний.
- Далее вычисляются собственные значения и собственные векторы центрированной матрицы B .
- Собственные значения сортируются в порядке убывания, и отбираются первые k собственных векторов, соответствующие наибольшим собственным значениям.
- Наконец, исходные данные проецируются в новое пространство размерности k с помощью матрицы проекции W , которая формируется из первых k собственных векторов.

Результатом является линейное преобразование, аналогичное PCA, но построенное на расстояниях, а не ковариациях.

Метод Uniform Manifold Approximation and Projection (UMAP) Метод Uniform Manifold Approximation and Projection (UMAP) [33], представляет собой современный и эффективный нелинейный алгоритм снижения размерности, ориентированный на сохранение локальной и глобальной структуры данных. В отличие от классических линейных методов (например, PCA), UMAP обладает высокой масштабируемостью, вычислительной эффективностью и устойчивостью к шуму, что делает его востребованным в задачах визуализации, кластеризации и предварительной обработки данных. Ключевые шаги алгоритма UMAP:

- Построение k -графа ближайших соседей для каждого объекта и определение вероятностного распределения локальных расстояний.
- Построение матрицы локальных связей с использованием параметров расстояния и плотности.
- Инициализация точек в пространстве меньшей размерности (обычно случайным образом или с использованием метода PCA).
- Проведение оптимизации с помощью стохастического градиентного спуска, минимизирующей перекрытие между графами высокого и низкого размерностей.

Метод Isometric Mapping (Isomap) Метод Isometric Mapping (Isomap) — это нелинейный алгоритм снижения размерности [42]. Isomap расширяет классический метод многомерного шкалирования (MDS), позволяя сохранить геодезические расстояния между точками на многообразии, а не только их евклидову дистанцию. Это делает метод особенно полезным для обработки данных, лежащих на нелинейных многообразиях высокой размерности.

Ключевая идея Isomap состоит в том, чтобы заменить евклидовы расстояния между объектами на приближённые геодезические расстояния, которые более точно отражают топологическую структуру данных на искривлённом многообразии. Геодезические расстояния определяются как кратчайшие пути вдоль поверхности (графа), аппроксимирующей пространство объектов. После этого используется метод классического MDS для получения координат в пространстве пониженной размерности. Алгоритм Isomap включает следующие шаги:

- Построение графа ближайших соседей, где для каждого объекта выбираются k ближайших соседей.
- Вычисление геодезических расстояний: определяется кратчайшее расстояние между всеми парами объектов по построенному графу с использова-

нием, например, алгоритма Флойда–Уоршелла или Дейкстры.

- Применение MDS: проводится классическое многомерное шкалирование на полученной матрице геодезических расстояний для проекции данных в пространство меньшей размерности.

Isomap позволяет эффективно обрабатывать данные с нелинейной структурой, сохраняя при этом важные топологические свойства. Однако метод требует значительных вычислительных ресурсов и может быть чувствителен к шуму в данных.

Метод Locally Linear Embedding (LLE) Метод Locally Linear Embedding (LLE) — это эффективный алгоритм нелинейного снижения размерности [37]. Он позволяет получить компактное представление высокоразмерных данных, сохранив при этом локальную геометрию исходного пространства. В отличие от линейных методов, таких как PCA, LLE способен выявлять нелинейные структуры, что делает его особенно полезным для обработки данных, лежащих на искривлённых многообразиях.

Идея LLE заключается в следующем: каждый объект в высокоразмерном пространстве аппроксимируется линейной комбинацией своих ближайших соседей. Предполагается, что на достаточно малых масштабах многообразие можно считать почти линейным. Эти веса затем используются для восстановления представления объекта уже в пространстве меньшей размерности, с сохранением локальной топологии. Метод LLE включает следующие этапы:

- Поиск ближайших соседей для каждого объекта. Обычно используется метрика евклидова расстояния и выбирается фиксированное число соседей k .
- Вычисление весов локальной линейной аппроксимации. Для каждого объекта находятся коэффициенты w_{ij} , минимизирующие ошибку реконструк-

ции $x_i \approx \sum_j w_{ij} x_j$, где x_j — ближайшие соседи точки x_i . Условия: $\sum_j w_{ij} = 1$, $w_{ij} = 0$, если x_j не является соседом x_i .

- Обратная реконструкция: минимизация расстояния между исходными весами и их аналогами в пространстве меньшей размерности — нахождение точек y_i , минимизирующих $\sum_i \|y_i - \sum_j w_{ij} y_j\|^2$.
- Решение задачи через собственные значения: нахождение низкоразмерного представления Y , соответствующего наименьшим собственным значениям результирующей матрицы.

Метод Spectral Embedding (SSE) Метод Spectral Embedding (SSE), также известный как спектральное разложение графа или Laplacian Eigenmaps, представляет собой мощный инструмент нелинейного снижения размерности [8]. SSE опирается на представление данных в виде графа, в котором вершины соответствуют объектам, а рёбра — их близости. Метод позволяет сохранить локальную геометрию данных, что делает его особенно эффективным для задач, связанных с визуализацией, сегментацией и кластеризацией структурно сложных данных.

Основной идеей метода является построение взвешенного графа ближайших соседей, после чего рассчитывается его нормализованный лапласиан, отражающий топологическую структуру данных. Далее проводится спектральное разложение лапласиана, и проекции объектов на собственные векторы, соответствующие наименьшим собственным значениям, формируют новое пространство признаков пониженной размерности. Метод SSE включает следующие этапы:

- Построение матрицы сходства S : используется гауссово ядро или функция ближайших соседей, чтобы определить степень связи между объектами.
- Формирование матрицы Лапласиана L : $L = D - S$, где D — диагональная матрица степеней вершин, $D_{ii} = \sum_j S_{ij}$.

- Вычисление собственных значений и собственных векторов матрицы L : выбираются k собственных векторов, соответствующих наименьшим ненулевым собственным значениям.
- Формирование проекционного пространства: используется матрица $W \in \mathbb{R}^{m \times k}$, содержащая выбранные собственные векторы.
- Получение проекции: $Z = W\Lambda^{1/2}$, где Λ — диагональная матрица собственных значений.

Обобщение

В ходе проведённого обзора были рассмотрены основные алгоритмы кластеризации, применяемые в задачах анализа многомерных данных. Одной из ключевых проблем, выявленных при этом, стало существенное снижение качества кластеризации в условиях высокой размерности признакового пространства. Такая ситуация, характерная для многих современных наборов данных, приводит к явлению, известному как проклятие размерности, при котором традиционные алгоритмы, включая k -Means, демонстрируют нестабильность, низкую точность результатов. Для преодоления этих ограничений активно применяются различные стратегии предварительной обработки данных, ключевую роль среди которых играет снижение размерности. Данный подход позволяет не только сократить вычислительную сложность алгоритмов, но и повысить устойчивость и точность кластеризации за счёт устранения шумовых и коррелированных признаков. Существует широкий спектр методов снижения размерности, начиная от линейных алгоритмов, таких как метод главных компонент (PCA) и метод многомерного шкалирования (MDS), и заканчивая нелинейными подходами, включая UMAP, Isomap, Locally Linear Embedding (LLE) и Spectral Embedding (SSE). Линейные методы, как правило, обеспечивают высокую интерпретируемость и простоту реализации, однако ограничены в возможности работы с данными, лежащими на искривлённых многообразиях. Нелинейные же подходы позво-

ляют более точно передавать сложные топологические структуры, но требуют аккуратной настройки и значительных вычислительных ресурсов. Несмотря на разнообразие существующих методов и их широкое применение, на практике остаётся ряд открытых проблем. Во-первых, не существует универсального критерия выбора метода снижения размерности для конкретной задачи кластеризации. Выбор подхода часто осуществляется эмпирически и зависит от множества факторов: характера данных, плотности распределения, предполагаемого количества кластеров и других параметров. Во-вторых, влияние предварительного понижения размерности на итоговое качество кластеризации далеко не всегда очевидно и требует тщательного эмпирического анализа. В-третьих, интеграция методов снижения размерности в общую процедуру кластеризации до сих пор часто остаётся фрагментарной и недостаточно формализованной.

3 Постановка проблемы

3.1 Основные обозначения

В дальнейшем будут использоваться следующие основные обозначения. Пусть $X = \begin{pmatrix} x_i^j \end{pmatrix} \in \mathbb{R}^{n \times d}$ обозначает матрицу наблюдений размером $n \times d$, где каждый d -мерный объект $x_i = (x_i^1, x_i^2, \dots, x_i^d) \in \mathbb{R}^{1 \times d}$ представляет собой строковый вектор признаков для каждого наблюдения $i = 1, 2, \dots, n$. Вектор $x_j = (x_1^j, x_2^j, \dots, x_n^j)^\top \in \mathbb{R}^{n \times 1}$ означает столбец значений признака j для всех наблюдений $j = 1, 2, \dots, d$. Вектор $y = (y_1, y_2, \dots, y_n)^\top \in \mathbb{R}^{n \times 1}$ содержит значения целевой функции, представляющей искомые кластеры. Число кластеров обозначено как k , а разбиение наблюдений на кластеры — как $S = S_1, S_2, \dots, S_k$, где каждый кластер $S_l \subset 1, 2, \dots, n$ для $l = 1, 2, \dots, k$. Набор из k центров кластеров представлен через $c = c_1, c_2, \dots, c_k$, где каждый центр $c_l = (c_l^1, c_l^2, \dots, c_l^d) \in \mathbb{R}^{1 \times d}$ для $l = 1, 2, \dots, k$. Также используется диагональная матрица размерности d , обозначенная как I_d .

3.2 Формулирование задачи кластеризации без учителя

Формальная запись задачи кластеризации «без учителя» имеет следующий вид: для каждого d -мерного объекта x_i из множества объектов $X = x_1, x_2, \dots, x_n$, необходимо поставить в соответствие один из k кластеров $c = \{c_1, c_2, \dots, c_k\}$.

Для оценивания «схожести» объектов могут быть использованы разные метрики расстояния такие как Евклидово расстояние [29], Манхеттенское расстояние, [25], расстояние Минковского [2] и другие. А также различные способы оценки межкластерных расстояний, такие как Average Linkage [49], Complete Linkage [14], Single Linkage [40].

В общем виде задача кластеризации на основе центроидов для расстояния Минковского с параметром p есть задача сложной невыпуклой оптимизации функционала качества (4), которая может быть решена с помощью эвристиче-

ского алгоритма k -Means для метрики Минковского, где необходимо оптимизировать сумму расстояний между объектами внутри кластеров.

$$W_p(S; c) = \sum_{l=1}^k \sum_{x \in S_l} \sum_{j=1}^d |x^j - c_l^j|^p \rightarrow \min, \quad (4)$$

$$x = (x^1, x^2, \dots, x^d) \in R^{1 \times d},$$

$$c_l = (c_l^1, c_l^2, \dots, c_l^d) \in R^{1 \times d}.$$

В данной работе рассматривается функционал кластеризации с Евклидовым расстоянием (метрика Минковского с параметром $p = 2$).

$$W_p(S; c) = \sum_{l=1}^k \sum_{x \in S_l} \sum_{j=1}^d |x^j - c_l^j|^2 \rightarrow \min. \quad (5)$$

3.2.1 Выбор метода кластеризации

В качестве основы для проведения анализа был выбран алгоритм кластеризации k -Means, поскольку k -Means – легко интерпретируемый подход, основанный на оптимизации суммарного квадратичного отклонения внутри кластеров. Выбор k -Means также обусловлен его основными преимуществами: простотой реализации (существует большое число реализаций и оптимизаций данного подхода), высокой скоростью работы (на небольших наборах данных алгоритм способен сходиться за очень короткое время).

Алгоритм k -Means выполняет кластеризацию данных, оптимизируя суммарное квадратичное отклонение внутри кластеров. Его работа состоит из нескольких этапов:

1. Инициализация. Фиксируется параметр k – число кластеров, которые необходимо найти, после чего центроиды кластеров выбираются случайным образом.
2. Присвоение данных кластерам. Каждый объект данных присваивается

кластеру, чей центроид на основе выбранной метрики расстояния окажется ближе всего.

3. Обновление центроидов. Центроиды пересчитываются на основе объектов из соответствующих кластеров.
4. Итеративное повторение шагов 1, 2 и 3.

3.2.2 Выбор метрики качества

Для оценки качества предложенного алгоритма кластеризации были выбраны метрики NMI , ARI , AMI .

Rand Index (RI) Rand Index является метрикой, используемой для измерения сходства между двумя различными кластеризациями или разбиениями одного и того же набора данных. Основная идея RI заключается в том, чтобы подсчитать долю пар объектов, которые находятся в одном и том же кластере в обоих разбиениях (кластеризациях). Для того чтобы определить RI , вводятся следующие обозначения. Пусть X – набор, состоящий из n объектов для кластеризации, в котором a пар объектов попали в один кластер, а b пар попали в разные кластеры. Тогда метрика Rand Index (RI) будет иметь вид:

$$RI = \frac{a + b}{C_2^n}. \quad (6)$$

Adjusted Rand Index (ARI) Adjusted Rand Index – скорректированная версия Rand Index, предназначенная для измерения сходства между двумя кластеризациями, путем корректировки метрики RI . ARI может принимать значения в промежутке $[0; 1]$, где значение 1 соответствует идентичным кластеризациям, а значение 0 означает, что кластеризации случайны.

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}, \quad (7)$$

где $E[RI]$ – оценка математического ожидания RI , а $\max(RI)$ – максимальное значение Rand Index, полученное в результате кластеризаций.

Mutual Information (MI) Mutual Information измеряет степени зависимости между двумя различными разбиениями одного и того же набора данных на кластеры. Обозначим за U и V два разбиения набора данных X , состоящего из n объектов, что $|U_i|$ – есть количество объектов в кластере U_i , а $|V_j|$ в кластере V_j . Обозначим энтропию за $H(U)$.

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{n} \log \frac{n|U_i \cap V_j|}{|U_i||V_j|}, \quad (8)$$

Adjusted Mutual Information (AMI) Adjusted Mutual Information нормализуется относительно максимальной величины, которую может принять взаимная информация, что позволяет оценивать сходство между разбиениями на независимых от размера кластеров данных. Она принимает значения в интервале от 0 до 1, где значение 1 означает идентичные разбиения, а значение 0 указывает на полное отсутствие сходства. Данная метрика широко используется в оценке качества различных методов кластеризации или сегментации данных, особенно когда требуется оценить сходство результатов, полученных из разных экспериментов или алгоритмов кластеризации.

$$AMI(U, V) = \frac{MI(U, V) - E[MI(U, V)]}{\text{mean}(H(U), H(V)) - E[MI(U, V)]}. \quad (9)$$

Normalized Mutual Information (NMI) Normalized Mutual Information – вариант MI , который нормализуется для того, чтобы значения можно было интерпретировать на отрезке от 0 до 1. Метрика используется для измерения сходства между двумя различными разбиениями одного и того же набора данных на кластеры.

$$NMI(U, V) = \frac{MI(U, V)}{\text{mean}(H(U), H(V))}. \quad (10)$$

4 Предложенный метод

Одним из способов решения проблемы «проклятия размерности» является применения этапа предварительного снижения размерности, позволяющий компактно представить данные в пространстве с меньшей размерностью, сохранив при этом ключевую топологическую структуру (Алгоритм 1).

Algorithm 1 Кластеризация с предварительным снижением размерности

k : Количество классов

X : Множество объектов

d_{target} : Размерность пространства, в котором будет производиться кластеризация

$C = \{C_1, C_2, \dots, C_k\}$: Разбиение на кластеры

$c = \{c_1, c_2, \dots, c_k\}$: Центры кластеров

$Processor()$: Выбранный метод снижения размерности

$X_{d_{target}} \leftarrow Processor(X, d_{target})$ – применить метод снижения размерности в пространство размерности d_{target} для данных X

Выбрать случайным образом k центров кластеров из $X_{d_{target}}$

while центры не стабилизировались **do**

for точка $x \in X$ **do**

 вычислить расстояние до каждого центра c

 присвоить x кластеру с ближайшим центром кластера

end for

for кластер $C_i \in C$ и центр $c_i \in c$ **do**

 пересчитать центр c_i кластера как среднее значение из точек внутри кластера C_i

end for

end while

Алгоритм был реализован при использовании языка программирования Python 3.10 и библиотеки *numpy* (1.24.3), *scikit-learn* (1.2.0), *scipy* (1.10.0), *umap-learn* (0.5.7). Для анализа результатов была разработана система автоматической генерации таблиц и графиков с использованием библиотеки *pandas* (1.5.2) и *matplotlib* (3.6.2). Для анализа качества алгоритма была разработана система автоматического анализа кода и тестирования алгоритма на платформе GitHub

Actions. Качество кода проверялось с использованием библиотек *pylint* (2.15.9) и *isort* (5.11.4). Для тестирования алгоритма были разработаны 168 Unit тестов с использованием библиотеки *pytest* (7.2.0).

4.1 Методы снижения размерности

В качестве методов снижения размерности были исследованы следующие методы:

- Principal Component Analysis (PCA),
- Spectral Embeddings (SE),
- Locally Linear Embedding (LLE),
- Multidimensional Scaling (MDS),
- Uniform Manifold Approximation and Projection (UMAP).
- Isometric Mapping (ISOMAP).

Algorithm 2 Метод главных компонент (PCA)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Стандартизация данных: $X_{\text{std}} = \frac{X - \mu}{\sigma}$, где μ – среднее значение, а σ – стандартное отклонение каждого признака.

Шаг 2: Вычисление ковариационной матрицы: $\Sigma = \frac{1}{n} X_{\text{std}}^T X_{\text{std}}$.

Шаг 3: Вычисление собственных значений и собственных векторов ковариационной матрицы: $\Sigma v_i = \lambda_i v_i$, где λ_i – собственные значения, а v_i – собственные векторы.

Шаг 4: Сортировка собственных значений и соответствующих им собственных векторов в порядке убывания $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$

Шаг 5: Выбор первых k собственных векторов для формирования матрицы проекции $W \in \mathbb{R}^{n \times k}$: $W = [v_1, v_2, \dots, v_k]$

Шаг 6: Преобразование исходных данных в новое подпространство: $Z = X_{\text{std}} W$

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k главными компонентами.

Метод главных компонент (Principal Component Analysis)

Algorithm 3 Метод многомерного шкалирования (MDS)

Require: Матрица попарных расстояний $D \in \mathbb{R}^{m \times m}$ между m объектами

Шаг 1: Вычисление матрицы квадратов попарных расстояний: $B = -\frac{1}{2}D^2$

Шаг 2: Центрирование матрицы B : $B = B - \frac{1}{m}\mathbf{1}B - \frac{1}{m}B\mathbf{1} + \frac{1}{m^2}\mathbf{1}B\mathbf{1}$, где $\mathbf{1}$ – матрица, заполненная единицами.

Шаг 3: Вычисление собственных значений и собственных векторов матрицы B : $Bv_i = \lambda_i v_i$, где λ_i – собственные значения, а v_i – собственные векторы.

Шаг 4: Сортировка собственных значений и соответствующих им собственных векторов в порядке убывания $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m$.

Шаг 5: Выбор первых k собственных векторов для формирования матрицы проекции $W \in \mathbb{R}^{m \times k}$: $W = [v_1, v_2, \dots, v_k]$.

Шаг 6: Преобразование исходных данных в новое подпространство: $Z = W\Lambda^{1/2}$, где Λ – диагональная матрица, содержащая k наибольших собственных значений.

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод многомерного шкалирования (Multidimensional Scaling)

Algorithm 4 Метод Uniform Manifold Approximation and Projection (UMAP)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Вычисление матрицы ближайших соседей и вероятностной структуры локального графа

Шаг 2: Построение глобального графа связи (средства соединения локальных графов)

Шаг 3: Инициализация точек в проекционном пространстве

Шаг 4: Оптимизация размещения точек с использованием перекрытия распределений

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Uniform Manifold Approximation and Projection (UMAP)

Algorithm 5 Метод Isometric Mapping (Isomap)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Построение графа ближайших соседей (по k ближайшим)

Шаг 2: Вычисление геодезических расстояний между всеми парами точек (алгоритм Флойда/Дейкстры)

Шаг 3: Применение MDS к матрице геодезических расстояний

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Isometric Mapping (Isomap)

Algorithm 6 Метод Locally Linear Embedding (LLE)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Найти k ближайших соседей для каждого x_i

Шаг 2: Решить задачу линейной аппроксимации и найти веса w_{ij}

Шаг 3: Построить матрицу весов W (разреженную)

Шаг 4: Выбор случайных точек в пространстве меньшей размерности

Шаг 5: Найти проекции y_i , минимизируя функцию ошибки реконструкции $\sum_i \|y_i - \sum_j w_{ij} y_j\|^2$

return Матрица данных с уменьшенной размерностью $Y \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Locally Linear Embedding (LLE)

Algorithm 7 Метод Spectral Embedding (SSE)

Require: Матрица данных $X \in \mathbb{R}^{m \times n}$ с m образцами и n признаками

Шаг 1: Построение матрицы сходства S

Шаг 2: Формирование матрицы Лапласиана $L = D - S$

Шаг 3: Спектральное разложение $L : Lv_i = \lambda_i v_i$

Шаг 4: Формирование матрицы проекции $W = [v_1, \dots, v_k]$

Шаг 5: Получение низкоразмерного представления $Z = W\Lambda^{1/2}$

return Матрица данных с уменьшенной размерностью $Z \in \mathbb{R}^{m \times k}$ с k измерениями.

Метод Spectral Embedding (SSE)

5 Результаты исследования

Алгоритм k -Means демонстрирует наилучшие результаты в тех случаях, когда данные обладают рядом специфических характеристик, создающих благоприятные условия для корректной работы метода. Прежде всего, речь идёт о сферической структуре кластеров: каждый кластер должен быть приблизительно симметричным относительно своего центра, а расстояния от центроидов до границ кластера – примерно одинаковыми. Такая конфигурация обеспечивает чёткую геометрическую интерпретацию центров масс и минимизирует ошибки при расчёте евклидовых расстояний. Не менее важным фактором является сходная плотность данных внутри кластеров. В тех случаях, когда плотность одной группы объектов значительно превышает плотность другой, k -Means может ошибочно объединить разреженные участки или, наоборот, раздробить плотную область на несколько частей. Алгоритм также чувствителен к степени разделённости кластеров: чем больше расстояние между группами по сравнению с их внутренним разбросом, тем выше вероятность корректного выделения кластеров. Последнее, но не менее значимое условие – однородность размеров кластеров. k -Means предпочитает, чтобы кластеры были схожи по объёму и радиусу, иначе велик риск, что объекты меньшего кластера окажутся «поглощёнными» более крупным.

В данной работе рассматриваются синтетические наборы, состоящие из смесей нормальных распределений с фиксированным Σ и μ . Плотность смеси нормальных распределений:

$$f(x) = \sum_{l=1}^k p_l f_l(x), \quad x = (x^1, x^2, \dots, x^d), p_l > 0, \sum_{l=1}^k p_l = 1.$$

Для каждого из синтетических наборов данных матрицы ковариаций фиксируются как единичные диагональные матрицы $\Sigma = I_d$. С помощью параметра t математические ожидания распределений могут быть сближены или разнесены

по правилу:

$$\mu_i(t) = \mu_i + t\left(\frac{\sum_{j=1}^k \mu_j}{k} - \mu_i\right), \quad 0 \leq t \leq 1, \forall i \in [1, k].$$

С целью получения надежных и воспроизводимых оценок качества кластеризации, результаты проводимых экспериментов были усреднены по 100 независимым запускам алгоритма, каждый из которых начинался с различной инициализации. Такой подход позволяет сгладить влияние случайных факторов, повысить статистическую значимость выводов и оценить стабильность найденных решений.

5.1 Эксперименты на синтетических данных

В данной главе рассматриваются синтетические наборы, состоящие из смесей нормальных распределений с фиксированным Σ и μ . Плотность смеси нормальных распределений:

$$f(x) = \sum_{l=1}^k p_l f_l(x), \quad x = (x^1, x^2, \dots, x^d), p_l > 0, \sum_{l=1}^k p_l = 1.$$

Для синтетических наборов данных матрицы ковариаций фиксируются как единичные диагональные матрицы $\Sigma = I_d$. С помощью параметра t математические ожидания распределений могут быть сближены или разнесены по правилу:

$$\mu_i(t) = \mu_i + t\left(\frac{\sum_{j=1}^k \mu_j}{k} - \mu_i\right), \quad 0 \leq t \leq 1, \forall i \in [1, k].$$

Для синтетического набора, состоящего из смеси 2 нормальных распределений, заданы математические ожидания по правилу:

$$\mu_1 = (-4, 0, 0, \dots)$$

$$\mu_2 = (4, 0, 0, \dots).$$

5.1.1 Анализ поведения методов снижения кластеризации при снижении числа компонент.

В данной части экспериментов исследуется влияние методов снижения размерности на поведение алгоритма кластеризации k -Means в условиях идеализированной структуры данных. Используемые синтетические выборки построены как смеси нормальных распределений с заранее заданными параметрами: идентичной дисперсией ($\Sigma = I_d$), равновесными априорными вероятностями кластеров и симметрично расположенными центрами μ_1 и μ_2 . Это обеспечивает выполнение всех условий, благоприятных для работы алгоритма k -Means: сферичность кластеров, равную плотность и размер, а также чёткое разделение между группами при $t < 0$. Таким образом, снижение размерности становится единственным фактором, искажающим исходную структуру данных.

Целью эксперимента является оценка того, насколько каждый из методов снижения размерности способен сохранить разделимость между кластерами при поэтапном сокращении размерности пространства от исходной размерности (20) до экстремально низкой (2).

На рисунке 1 представлены графики зависимости качества кластеризации от числа компонент после снижения размерности при параметре $t = 0.4$, что соответствует умеренному уровню перекрытия между кластерами. Этот сценарий позволяет оценить способность методов сохранять полезную кластерную структуру без избыточной плотности или разреженности данных.

Исходя из графиков, можно выделить явного лидера – метод PCA, который стабильно показывает максимальные значения метрик (порядка 0.9 и выше) при любом количестве оставляемых компонент. Это указывает на эффективное сохранение линейной структуры синтетических данных, особенно в случаях, когда кластеры умеренно разделены. MDS, а также ISOMAP и UMAP, дают сопоставимо высокие результаты, практически не зависящие от количества компонент, что говорит о слабой деградации качества даже при сильном снижении раз-

мерности данных. Locally Linear Embeddings и Spectral Embeddings, напротив, демонстрируют выраженную чувствительность к размерности. С уменьшением числа компонент качество кластеризации постепенно улучшается и достигает пика на размерности равной числу заложенных кластеров.




Рис. 1: Анализ влияния размерности данных при различных методах снижения размерности на кластеризацию синтетического набора данных с параметром $t = 0.4$. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 2 представлен анализ влияния количества компонент, оставляе-

мых после снижения размерности, на качество кластеризации при фиксированном значении параметра $t = 0.8$, соответствующем сильному перекрытию кластеров. На этом уровне разделимость между группами минимальна, что делает задачу особенно чувствительной к качеству понижения размерности. Также, следует, что методы PCA демонстрирует наилучшую устойчивость и качество кластеризации вне зависимости от числа компонент. В противоположность, методы Locally Linear Embeddings и Spectral Embeddings показывают низкие и слабо возрастающие значения всех метрик при уменьшении количества компонент, что говорит о неэффективном представлении кластерной структуры в условиях высокой плотности и перекрытия.

Таким образом, при высоком уровне наложения кластеров (большое t) и варьируемом числе компонент, наиболее стабильные и надёжные результаты обеспечивают методы PCA и MDS. Остальные методы, особенно LLE и Spectral, оказываются крайне чувствительными к размерности и не рекомендованы к применению в таких условиях.



Рис. 2: Анализ влияния размерности данных при различных методах снижения размерности на кластеризацию синтетического набора данных с параметром $t = 0.8$. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

Таким образом, эксперимент подтвердил, что даже в условиях идеальной геометрии кластеров агрессивное снижение размерности способно существенно нарушить пространственную структуру, необходимую для корректной работы k -Means. Наиболее устойчивыми к снижению размерности оказались методы PCA и MDS. Это подчёркивает важность выбора метода снижения размерности.

сти в зависимости от допустимой степени искажения данных при сохранении кластерной структуры.

5.1.2 Анализ поведения методов снижения кластеризации при сближении кластеров.

В данной части экспериментов особое внимание уделяется анализу устойчивости и адаптивности различных методов снижения размерности в условиях, когда кластеры в данных становятся всё менее различимыми – то есть постепенно сближаются в пространстве признаков. Синтетическая модель, построенная как смесь нормальных распределений с контролируемым расстоянием между центрами кластеров, позволяет формализованно варьировать степень перекрытия кластеров с помощью параметра t , не изменяя другие характеристики выборки.

В условиях, когда $t < 0$, центры кластеров максимально удаляются друг от друга без пересечений, что соответствует идеальному случаю для алгоритма k -Means. По мере увеличения значения t до 1 центры притягиваются к общему центру масс, и границы между кластерами становятся всё менее чёткими, что моделирует реальные сценарии, в которых классы могут частично перекрываться. Такой подход позволяет объективно оценить, насколько методы понижения размерности сохраняют или теряют разделимость между группами при убывающем межкластерном расстоянии.

Результаты экспериментов продемонстрированы на рисунке 3, и показали высокую степень чувствительности к росту перекрытия кластеров.

При анализе показателей AMI, ARI и NMI можно наблюдать устойчивое превосходство методов MDS, ISOMAP и UMAP на всех значениях параметра t , особенно в областях, где кластеры хорошо разделены ($t < 0.4$). Эти методы демонстрируют почти идеальное восстановление кластерной структуры при низких значениях t , что соответствует высокой степени отделённости кластеров. С увеличением t все методы, за исключением Spectral Embeddings и Locally

Linear Embeddings (LLE), относительно стабильно теряют качество, однако сохраняют приемлемый уровень информативности вплоть до $t \approx 0.6$. В то же время, методы Spectral и LLE показывают значительно худшие показатели на всех интервалах t , демонстрируя явную нестабильность и уязвимость к изменению межкластерного расстояния.

Особенно интересным является пик значений метрик (в районе $t = 0.4$) для Spectral и LLE, что может быть обусловлено локальным улучшением связности графов при частичном сближении кластеров. Однако после этого значения происходит резкое падение метрик, особенно AMI и NMI, указывающее на неспособность этих методов сохранять глобальную структуру данных при сильном перекрытии.

С точки зрения времени выполнения, наиболее ресурсоёмкими методами оказались Spectral Embeddings и ISOMAP, особенно в зонах частичного перекрытия кластеров. Напротив, PCA, MDS и UMAP демонстрируют не только высокое качество кластеризации, но и эффективность по времени, что делает их особенно предпочтительными для задач, требующих баланса между точностью и скоростью.

Таким образом, в условиях постепенно сближающихся кластеров методы MDS, UMAP и ISOMAP оказываются наиболее надёжными как по качеству кластеризации, так и по вычислительным затратам. Методы Spectral и LLE, напротив, показали нестабильное поведение и склонность к деградации качества при увеличении параметра t .




Рис. 3: Анализ влияния различных методов снижения размерности данных на кластеризацию синтетического набора данных при сближении и отдалении центров кластеров. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

Таким образом, анализ на синтетических данных подтвердил, что эффективность методов снижения размерности сильно зависит от геометрии и плотности кластеров. Это подчёркивает необходимость адаптивного выбора метода снижения размерности в зависимости от ожидаемой сложности кластерной структуры в данных.

5.2 Эксперименты на реальных данных

Также предложенный подход был исследован на реальных данных. Для этого было решено использовать несколько стандартных наборов данных:

- Breast Cancer [48],
- Digits [3],
- Wine [1].

5.2.1 Результаты алгоритма на наборе данных Breast Cancer.

Breast Cancer – это стандартный набор данных для бинарной классификации, часто используемый в задачах медицинской диагностики. Данные содержат результаты измерений опухолей молочной железы, полученные при помощи тонкоигольной аспирационной биопсии (FNA). Каждая запись включает характеристики клеточных ядер, такие как радиус, текстура, периметр и другие морфологические признаки.

Таблица 1: Характеристики набора данных Breast Cancer.

Число классов	Число объектов	Размерность пространства
2	569	30

Набор данных Breast Cancer представляет собой матрицу размерностью 569x30, где каждая строка соответствует отдельному образцу опухоли, а каждый столбец содержит числовое значение одного из диагностических признаков. Целевая переменная указывает на доброкачественность (benign) или злокачественность (malignant) новообразования. Данные часто используются для обучения моделей машинного обучения, направленных на автоматизацию диагностики рака молочной железы.




Рис. 4: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Breast Cancer. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 4 представлены результаты применения различных методов снижения размерности перед кластеризацией K-Means на наборе данных Breast Cancer. Наиболее заметную положительную динамику продемонстрировали методы Locally Linear Embedding (LLE) и Spectral Embedding – при уменьшении размерности до 10 и ниже наблюдается последовательный рост метрик кластеризации: AMI, ARI и NMI. Пиковые значения достигаются в точке, где число

компонент совпадает с числом кластеров в выборке, что может свидетельствовать о более точной структурной декомпозиции, когда размерность пространства отражает истинное количество скрытых групп. В то же время алгоритмы PCA и MDS демонстрируют стабильные показатели качества, близкие к базовому сценарию кластеризации без предварительного снижения размерности. Это указывает на то, что оба метода хорошо сохраняют глобальную структуру данных, которая является ключевой для работы алгоритма K-Means. Особенно стоит отметить MDS, который обеспечивает не только стабильность качества, но и высокую воспроизводимость результатов на всем диапазоне размерностей. Такое поведение подтверждает различия в подходах: методы LLE и Spectral Embedding склонны акцентировать внимание на локальных взаимосвязях между точками, что делает их полезными при сильной редукции, в то время как PCA и MDS сохраняют глобальную топологию, важную для более устойчивой кластеризации.

5.2.2 Результаты алгоритма на наборе данных Digits.

Digits – это стандартный набор данных для многоклассовой классификации, часто используемый в задачах распознавания образов. Данные представляют собой рукописные цифры от 0 до 9, оцифрованные в виде изображений 8x8 пикселей. Каждое изображение преобразовано в матрицу чисел, отражающих интенсивность оттенков серого.

Таблица 2: Характеристики набора данных Digits.

Число классов	Число объектов	Размерность пространства
10	1797	64

Набор данных Digits представляет собой матрицу размерностью 1797x64, где каждая строка соответствует одному изображению цифры, а каждый столбец содержит значение яркости пикселя (от 0 до 16). Исходные изображения были

нормализованы для уменьшения влияния вариаций наклона и толщины линий.




Рис. 5: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Digits. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 5 представлены результаты экспериментов на датасете Digits. Следует отметить, что из-за ограничений существующей программной реализации методы MDS и Locally Linear Embedding не смогли корректно выполнить процедуру снижения размерности на этом наборе данных и, таким образом, были исключены из анализа. Среди протестированных алгоритмов ярким ли-

дером оказался ISOMAP, который уверенно превзошёл остальные методы по всем основным метрикам кластеризации - AMI, ARI и NMI. Он продемонстрировал стабильное превосходство над базовой линией (результат кластеризации без снижения размерности) вплоть до размерности в 2 компоненты, что говорит о его способности сохранять глобальную геометрию данных даже в сильно сжатом пространстве. Метод PCA продемонстрировал устойчивую деградацию качества кластеризации при уменьшении числа компонент, особенно заметную ниже порога в 10 компонент. Это отражает его ограниченность в улавливании нелинейных зависимостей в данных. Spectral Embedding, напротив, показал результаты в целом ниже уровня базового k -Means, что может объясняться тем, что он оптимизирует локальные отношения между точками, а не глобальную структуру. Тем не менее, на размерности, равной числу кластеров, наблюдался кратковременный всплеск метрик, что, вероятно, связано с тем, что алгоритм эффективно извлекает локальные кластеры, когда размерность достаточно для сохранения этих структур. Также была выявлена интересная зависимость по времени выполнения: ISOMAP, несмотря на свою сложность, в среднем демонстрировал сравнительно низкое время работы с редкими всплесками, что делает его не только точным, но и потенциально пригодным для практического применения при разумной конфигурации.

5.2.3 Результаты алгоритма на наборе данных Wine.

Wine – это стандартный и простой набор данных для многоклассовой классификации. Эти данные являются результатами химического анализа вин, выращенных в одном и том же регионе Италии тремя разными производителями. Существует тринадцать различных измерений, проведенных для различных компонентов, содержащихся в трех сортах вина.

Таблица 3: Характеристики набора данных Wine.

Число классов	Число объектов	Размерность пространства
3	178	13

Набор данных Wine представляет собой матрицу с размерностью 178x13, где каждая строка соответствует отдельному образцу вина, а каждый столбец содержит значение конкретного химического измерения.




Рис. 6: Анализ влияния различных методов снижения размерности данных на кластеризацию набора данных Wine. Линия Baseline – результат работы алгоритма k -Means без предварительного снижения размерности. Результаты для (a) AMI; (b) ARI; (c) NMI, а также на время работы алгоритма (d).

На рисунке 6 представлены результаты экспериментов по кластеризации с предварительным снижением размерности на наборе данных Wine. Анализ показал, что методы PCA, ISOMAP и UMAP обеспечивают устойчивое поведение метрик, оставаясь на уровне или вблизи базовой линии на всем диапазоне компонент. Однако, несмотря на эту стабильность, они не продемонстрировали прироста качества кластеризации при уменьшении размерности. В то же время,

методы Locally Linear Embedding (LLE) и Spectral Embedding показали заметное улучшение показателей AMI, ARI и NMI при переходе к малым числам компонент (2–4). Это указывает на их способность извлекать более информативную структуру данных в условиях значительного снижения размерности. Тем не менее, даже при росте метрик, их абсолютные значения остаются ниже по сравнению с другими методами, что ограничивает их практическую эффективность в этом конкретном примере. Важно отметить интересную закономерность: как ISOMAP, так и UMAP демонстрируют снижение качества кластеризации при переходе к размерностям, меньшим, чем реальное количество классов в выборке. Это может быть связано с потерей кластерной структуры, «неукладывающейся» в сжатое пространство. Такая деградация указывает на важность учета семантической емкости признакового пространства при выборе числа компонент. По времени выполнения алгоритма наилучшую стабильность и скорость показали MDS и PCA, что делает их предпочтительными с точки зрения вычислительной эффективности, особенно в сценариях, где время критично.

6 Заключение

Код проекта доступен по ссылке www.github.com/alexgiving/LKMeans.

Применение суперкомпьютерного комплекса CHARISMA. Исследование выполнено с использованием суперкомпьютерного комплекса НИУ ВШЭ [27].

Описание применения генеративной модели. В выпускной квалификационной работе использовалась генеративная модель DeepSeek-V3 Chat [13], доступная по ссылке www.deepseek.com. Модель была применена для систематизации и первичного структурирования обзора литературы, что позволило выделить ключевые направления исследований и логично выстроить анализ научных источников. Кроме того, модель использовалась для оформления $\text{\LaTeX}$ шаблона работы в соответствии с требованиями НИУ ВШЭ, включая корректное применение стилей, разметки и форматирования. Все сгенерированные фрагменты были переработаны и проверены автором вручную. Итоговый текст работы представляет собой результат анализа, интерпретации и авторского изложения материала.

Список литературы

- [1] S. Aeberhard and M. Forina, “Wine,” UCI Machine Learning Repository, 1992, DOI: <https://doi.org/10.24432/C5PC7J>.
- [2] C. C. Aggarwal, A. Hinneburg, and D. A. Keim, “On the surprising behavior of distance metrics in high dimensional spaces,” in *Proceedings of the 8th International Conference on Database Theory*, ser. ICDT '01. Berlin, Heidelberg: Springer-Verlag, 2001, p. 420–434.
- [3] E. Alpaydin and C. Kaynak, “Optical recognition of handwritten digits,” UCI Machine Learning Repository, 1998, DOI: <https://doi.org/10.24432/C50P49>.
- [4] M. Ankerst, M. M. Breunig, H.-P. Kriegel, and J. Sander, “Optics: Ordering points to identify the clustering structure,” *SIGMOD Rec.*, vol. 28, no. 2, p. 49–60, jun 1999. [Online]. Available: <https://doi.org/10.1145/304181.304187>
- [5] V. Antoine, N. Labroche, and V.-V. Vu, “Evidential seed-based semi-supervised clustering,” in *2014 Joint 7th International Conference on Soft Computing and Intelligent Systems (SCIS) and 15th International Symposium on Advanced Intelligent Systems (ISIS)*, 2014, pp. 706–711.
- [6] D. Arthur and S. Vassilvitskii, “k-means++: the advantages of careful seeding,” in *SODA '07: Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 2007, pp. 1027–1035.
- [7] S. Basu, A. Banerjee, and R. J. Mooney, “Semi-supervised clustering by seeding,” in *Proceedings of the Nineteenth International Conference on Machine Learning*, ser. ICML '02. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2002, p. 27–34.
- [8] M. Belkin and P. Niyogi, “Laplacian eigenmaps and spectral techniques for

embedding and clustering,” *Advances in Neural Information Processing System*, vol. 14, 04 2002.

- [9] R. Bellman, *Dynamic Programming*, 1st ed. Princeton, NJ, USA: Princeton University Press, 1957.
- [10] K. Beyer, J. Goldstein, R. Ramakrishnan, and U. Shaft, “When is “nearest neighbor” meaningful?” in *Database Theory — ICDT’99*, C. Beeri and P. Buneman, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 1999, pp. 217–235.
- [11] R. Cordeiro de Amorim and B. Mirkin, “Minkowski metric, feature weighting and anomalous cluster initializing in k-means clustering,” *Pattern Recognition*, vol. 45, no. 3, pp. 1061–1075, 2012. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320311003517>
- [12] R. C. de Amorim and P. Komisarczuk, “On initializations for the minkowski weighted k-means,” in *Advances in Intelligent Data Analysis XI*, J. Hollmén, F. Klawonn, and A. Tucker, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2012, pp. 45–55.
- [13] DeepSeek-AI, “Deepseek-v3 technical report,” 2024. [Online]. Available: <https://arxiv.org/abs/2412.19437>
- [14] D. Defays, “An efficient algorithm for a complete link method,” *The Computer Journal*, vol. 20, no. 4, pp. 364–366, 01 1977. [Online]. Available: <https://doi.org/10.1093/comjnl/20.4.364>
- [15] A. Demidovskij, A. Tugaryov, A. Trutnev, M. Kazyulina, I. Salnikov, and S. Pavlov, “Lightweight and elegant data reduction strategies for training acceleration of convolutional neural networks,” *Mathematics*, vol. 11, no. 14, 2023. [Online]. Available: <https://www.mdpi.com/2227-7390/11/14/3120>

- [16] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, ser. KDD’96. AAAI Press, 1996, p. 226–231.
- [17] M. Grootendorst, “Bertopic: Neural topic modeling with a class-based tf-idf procedure,” 03 2022.
- [18] J. Gui, T. Chen, J. Zhang, Q. Cao, Z. Sun, H. Luo, and D. Tao, “A survey on self-supervised learning: Algorithms, applications, and future trends,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 12, pp. 9052–9071, 2024.
- [19] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant, “Array programming with NumPy,” *Nature*, vol. 585, no. 7825, pp. 357–362, Sept. 2020. [Online]. Available: <https://doi.org/10.1038/s41586-020-2649-2>
- [20] D. Hebb, “The organization of behavior: A neuropsychological theory,” 1949.
- [21] Z. Jiang, Y. Zhan, Q. Mao, and Y. Du, “Semi-supervised clustering under a “compact-cluster” assumption,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 5, pp. 5244–5256, 2023.
- [22] I. Jolliffe and J. Cadima, “Principal component analysis: A review and recent developments,” *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 374, p. 20150202, 04 2016.
- [23] I. Jolliffe, *Principal Component Analysis*. Springer Verlag, 1986.

- [24] L. Kaufman and P. Rousseeuw, *Finding Groups in Data: An Introduction To Cluster Analysis*, 01 1990.
- [25] L. Kaufman and P. J. Rousseeuw, *Partitioning Around Medoids (Program PAM)*. John Wiley & Sons, Inc., 2008, pp. 68–125. [Online]. Available: <http://dx.doi.org/10.1002/9780470316801.ch2>
- [26] V. Kiselev, T. Andrews, and M. Hemberg, “Challenges in unsupervised clustering of single-cell rna-seq data,” *Nature Reviews Genetics*, vol. 20, p. 1, 01 2019.
- [27] P. Kostenetskiy, R. Chulkevich, and V. Kozyrev, “Hpc resources of the higher school of economics,” *Journal of Physics: Conference Series*, vol. 1740, p. 012050, 01 2021.
- [28] J. B. Kruskal, “Nonmetric multidimensional scaling: A numerical method,” *Psychometrika*, vol. 29, pp. 115–129, 1964. [Online]. Available: <https://api.semanticscholar.org/CorpusID:11709679>
- [29] S. Lloyd, “Least squares quantization in pcm,” *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.
- [30] Y. Luo, K. Zhang, Y. Chai, and Y. Xiong, “Multi-parameter-setting based on data original distribution for denclue optimization,” *IEEE Access*, vol. 6, pp. 16 704–16 711, 2018.
- [31] L. McInnes, J. Healy, and S. Astels, “hdbscan: Hierarchical density based clustering,” *The Journal of Open Source Software*, vol. 2, 03 2017.
- [32] —, “hdbscan: Hierarchical density based clustering,” *The Journal of Open Source Software*, vol. 2, 03 2017.
- [33] L. McInnes, J. Healy, and J. Melville, “Umap: Uniform manifold

approximation and projection for dimension reduction,” 2020. [Online]. Available: <https://arxiv.org/abs/1802.03426>

- [34] F. Murtagh and P. Legendre, “Ward’s hierarchical agglomerative clustering method: Which algorithms implement ward’s criterion?” *Journal of Classification*, vol. 31, no. 3, pp. 274–295, Oct 2014. [Online]. Available: <https://doi.org/10.1007/s00357-014-9161-z>
- [35] R. Ng and J. Han, “Clarans: A method for clustering objects for spatial data mining,” *Knowledge and Data Engineering, IEEE Transactions on*, vol. 14, pp. 1003– 1016, 10 2002.
- [36] M. Ringnér, “What is principal component analysis?” *Nature Biotechnology*, vol. 26, pp. 303–4, 04 2008.
- [37] S. Roweis and L. Saul, “Nonlinear dimensionality reduction by locally linear embedding,” *Science (New York, N.Y.)*, vol. 290, pp. 2323–6, 01 2001.
- [38] D. Sculley, “Web-scale k-means clustering,” in *Proceedings of the 19th International Conference on World Wide Web*, ser. WWW ’10. New York, NY, USA: Association for Computing Machinery, 2010, p. 1177–1178. [Online]. Available: <https://doi.org/10.1145/1772690.1772862>
- [39] S. Setyaningsih, “Using cluster analysis study to examine the successful performance entrepreneur in indonesia,” *Procedia Economics and Finance*, vol. 4, pp. 286–298, 2012, international Conference on Small and Medium Enterprises Development with a Theme ?Innovation and Sustainability in SME Development? (ICSMED 2012). [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2212567112003437>
- [40] R. Sibson, “SLINK: An optimally efficient algorithm for the single-link cluster method,” *The Computer Journal*, vol. 16, no. 1, pp. 30–34, 01 1973. [Online]. Available: <https://doi.org/10.1093/comjnl/16.1.30>

- [41] B. Sorscher, R. Geirhos, S. Shekhar, S. Ganguli, and A. Morcos, “Beyond neural scaling laws: beating power law scaling via data pruning,” in *Advances in Neural Information Processing Systems*, S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, Eds., vol. 35. Curran Associates, Inc., 2022, pp. 19 523–19 536.
- [42] J. B. Tenenbaum, V. de Silva, and J. C. Langford, “A global geometric framework for nonlinear dimensionality reduction,” *Science*, vol. 290, no. 5500, pp. 2319–2323, 2000. [Online]. Available: <https://www.science.org/doi/abs/10.1126/science.290.5500.2319>
- [43] M. Turk and A. Pentland, “Eigenfaces for recognition,” *Journal of Cognitive Neuroscience*, vol. 3, no. 1, pp. 71–86, 1991.
- [44] L. van der Maaten and G. Hinton, “Visualizing data using t-sne,” *Journal of Machine Learning Research*, vol. 9, no. 86, pp. 2579–2605, 2008. [Online]. Available: <http://jmlr.org/papers/v9/vandermaaten08a.html>
- [45] G. Van Rossum and F. L. Drake, *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace, 2009.
- [46] M. Verleysen and D. François, “The curse of dimensionality in data mining and time series prediction,” in *International Work-Conference on Artificial and Natural Neural Networks*, 2005. [Online]. Available: <https://api.semanticscholar.org/CorpusID:9343744>
- [47] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, S. J. van der Walt, M. Brett, J. Wilson, K. J. Millman, N. Mayorov, A. R. J. Nelson, E. Jones, R. Kern, E. Larson, C. J. Carey, Í. Polat, Y. Feng, E. W. Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, E. A. Quintero, C. R. Harris, A. M. Archibald, A. H. Ribeiro, F. Pedregosa, P. van Mulbregt, and SciPy 1.0

Contributors, “SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.

- [48] W. Wolberg *et al.*, “Breast cancer wisconsin (diagnostic),” UCI Machine Learning Repository, 1993, DOI: <https://doi.org/10.24432/C5DW2B>.
- [49] N. Xu, R. B. Finkelman, S. Dai, C. Xu, and M. Peng, “Average linkage hierarchical clustering algorithm for determining the relationships between elements in coal,” *ACS Omega*, vol. 6, no. 9, pp. 6206–6217, 2021, pMID: 33718711. [Online]. Available: <https://doi.org/10.1021/acsomega.0c05758>